


Supervivencia en Cáncer de Mama y Pulmón: Identificación de Biomarcadores Genómicos Pronósticos mediante Modelos Estadísticos Avanzados y Validación Cruzada en Cohortes Independientes



Universitat Oberta
de Catalunya



UNIVERSITAT DE
BARCELONA

Julio Úbeda Quesada

**Medicina – Análisis de la supervivencia
del cáncer**

Máster Universitario en Ciencia de Datos

Nombre del director/a de TF:

Antonio Ruiz Falco Rojas

Nombre del/de la PRA:

Laia Subirats Maté

26 de febrero de 2026



Esta obra está sujeta a una licencia de Reconocimiento

<https://creativecommons.org/licenses/by-nc/3.0/es/>

Ficha Del Trabajo

Título del trabajo:	Supervivencia en Cáncer de Mama y Pulmón: Identificación de Biomarcadores Genómicos Pronósticos mediante Modelos Estadísticos Avanzados y Validación Cruzada en Cohortes Independientes
Nombre del autor/a:	Julio Úbeda Quesada
Nombre del director/a de TF:	Antonio Ruiz Falco Rojas
Nombre del/de la PRA:	Laia Subirats Maté
Fecha de entrega:	XX de XX de 2026
Titulación o programa:	Máster en Ciencia de Datos
Área del trabajo final:	Medicina
Idioma del trabajo:	Castellano
Palabras clave:	Cáncer de mama, cáncer de pulmón, aprendizaje profundo, factores genéticos, análisis de supervivencia

Resumen del trabajo

El cáncer es una de las principales causas de mortalidad a nivel mundial, con cerca de 10 millones de muertes en 2022 según la Organización Mundial de la Salud. La heterogeneidad molecular de los tumores dificulta que los factores clínicos tradicionales permitan estimar con precisión el pronóstico y la supervivencia. En este escenario, la disponibilidad creciente de datos genómicos de alta dimensionalidad y el desarrollo de técnicas de aprendizaje automático abren nuevas posibilidades para construir modelos pronósticos más precisos y personalizados.

Este Trabajo de Fin de Máster tiene como objetivo desarrollar, entrenar y comparar distintos modelos de análisis de supervivencia en pacientes con cáncer de mama y cáncer de pulmón. Para ello, se utilizarán datos genómicos procedentes de dos cohortes independientes y ampliamente empleadas en investigación: *The Cancer Genome Atlas* (TCGA) y METABRIC (*Molecular Taxonomy of Breast Cancer International Consortium*). Estas fuentes públicas, bien documentadas y consolidadas en la literatura científica, permiten garantizar la calidad de los datos y facilitar la comparación con estudios previos.

Se implementarán el estimador de Kaplan-Meier, el modelo de riesgos proporcionales de Cox, Random Survival Forest y el modelo de aprendizaje profundo DeepSurv. La evaluación se realizará mediante métricas estándar como el C-index, el Brier Score y el log-rank test, utilizando validación cruzada k-fold para asegurar la generalización. El análisis comparativo entre cohortes permitirá valorar la robustez y transferibilidad de los modelos, así como su contribución al avance de la medicina de precisión en oncología.

Abstract

Cancer remains one of the leading causes of death worldwide, accounting for nearly 10 million deaths in 2022 according to the World Health Organization. The molecular heterogeneity of tumors limits the ability of traditional clinical factors to accurately estimate prognosis and survival. In this context, the increasing availability of high-dimensional genomic data, together with advances in machine learning, creates new opportunities to develop more accurate and personalized prognostic models.

This Master's Thesis aims to develop, train, and compare different survival analysis models in patients with breast cancer and lung cancer. Genomic data from two independent and widely used research cohorts will be analyzed: The Cancer Genome Atlas and METABRIC (Molecular Taxonomy of Breast Cancer International Consortium). These publicly available and well-documented datasets are extensively used in the scientific literature, ensuring data quality and enabling comparison with previous studies.

The methodological approach includes the implementation of the Kaplan–Meier estimator, the Cox proportional hazards model, Random Survival Forest, and the deep learning model DeepSurv. Model performance will be evaluated using standard metrics such as the concordance index (C-index), the Brier Score, and the log-rank test, combined with k-fold cross-validation to ensure generalizability. The comparative analysis across cohorts will allow assessment of model robustness and transferability across different population characteristics, contributing to the advancement of precision oncology.

Contenido

CAPÍTULO 1: INTRODUCCIÓN	1
<u>1.1 Contexto y justificación del trabajo</u>	<u>1</u>
1.1.1 Situación actual de la supervivencia en cáncer	1
1.1.2 Relevancia del análisis de supervivencia en oncología	1
1.1.3 Papel de los factores genéticos en el pronóstico oncológico	2
1.1.4 Limitaciones actuales en modelos predictivos	2
1.1.5 Propuesta concreta de tipos de cáncer y justificación	3
1.1.6 Conjuntos de datos propuestos – Tabla comparativa	3
<u>1.2 Objetivos del trabajo</u>	<u>4</u>
1.2.1 Objetivo general	4
1.2.2 Objetivos específicos	4
<u>1.3 Impacto en sostenibilidad, ético-social y diversidad</u>	<u>5</u>
1.3.1 Impacto ético del uso de datos genéticos	5
1.3.2 Protección de datos y privacidad	5
1.3.3 Sesgos en conjuntos de datos biomédicos y equidad sanitaria	5
1.3.4 Relevancia social del trabajo	6
1.3.5 Protocolo ético y protección de datos	6
<u>1.4 Enfoque y método seguido</u>	<u>6</u>
1.4.1 Tipo de estudio	7
1.4.2 Pipeline metodológico	7
1.4.3 Técnicas de análisis de supervivencia	7
1.4.4 Métricas de evaluación	8
<u>1.5 Planificación del trabajo</u>	<u>8</u>
1.5.1 Fases, tareas, entregables e hitos	8
1.5.2 Diagrama de Gantt con planificación del TFM	9
1.5.3 Tabla de riesgos y mitigaciones	11
<u>1.6 Breve resumen de productos obtenidos</u>	<u>13</u>
<u>1.7 Breve descripción de los otros capítulos</u>	<u>14</u>
<u>1.8 Declaración sobre uso de inteligencia artificial generativa</u>	<u>15</u>
CAPÍTULO 2: ESTADO DEL ARTE	17
<u>2.1 Introducción al capítulo</u>	<u>17</u>
<u>2.2 Evolución histórica de los métodos de análisis de supervivencia</u>	<u>17</u>

2.2.1 El estimador de Kaplan-Meier	18
2.2.2 El modelo de riesgos proporcionales de Cox	18
<u>2.3 Métodos de aprendizaje automático para análisis de supervivencia.....</u>	18
2.3.1 Motivación del enfoque de machine learning	18
2.3.2 Random Survival Forest	19
2.3.3 Gradient Boosting para supervivencia	19
<u>2.4 Modelos de aprendizaje profundo para análisis de supervivencia.....</u>	19
2.4.1 DeepSurv.....	19
2.4.2 SurvivalNet y arquitecturas alternativas	20
2.4.3 Pipeline metodológico integrado	20
<u>2.5 Datos genómicos en la predicción del pronóstico oncológico.....</u>	21
2.5.1 El proyecto TCGA y su impacto en la investigación	21
2.5.2 El conjunto de datos METABRIC	21
2.5.3 Tipos de datos genómicos y su contribución pronóstica	22
<u>2.6 Estado del arte en cáncer de mama.....</u>	22
2.6.1 Clasificación molecular y pronóstico	22
2.6.2 Modelos de supervivencia basados en TCGA-BRCA y/o METABRIC	22
2.6.3 Tabla resumen de estudios en cáncer de mama.....	23
<u>2.7 Estado del arte en cáncer de pulmón no microcítico (NSCLC).....</u>	24
2.7.1 Heterogeneidad molecular y relevancia pronóstica	24
2.7.2 Modelos de supervivencia basados en datos genómicos y machine learning..	24
2.7.3 Tabla resumen de estudios en cáncer de pulmón	25
<u>2.8 Validación cruzada entre conjuntos de datos y generalización de modelo</u>	26
2.8.1 Importancia y estado actual	26
2.8.2 Estudios de validación TCGA – METABRIC	26
<u>2.9 Métricas de evaluación en modelos de supervivencia</u>	27
2.9.1 El índice de concordancia (C-index).....	27
2.9.2 El Brier Score integrado	27
2.9.3 El test de log-rank y la estratificación de riesgo.....	28
<u>2.10 Síntesis comparativa y brechas de conocimiento</u>	28
2.10.1 Comparativa de C-index por familia metodológica.....	28
2.10.2 Cuadro resumen global de metodologías y líneas de trabajo.....	28
2.10.3 Brechas de conocimiento identificadas.....	30

CAPÍTULO 3. MATERIAL Y MÉTODOS	32
<u>3.1. Diseño general del estudio.....</u>	32
<u>3.2. Fuentes de datos y cohortes analizadas</u>	32
3.2.1. Cohorte METABRIC	33
3.2.2. Cohorte TCGA-BRCA	33
3.2.3. Cohorte MSK-NSCLC	33
<u>3.3. Estrategia de adquisición de datos</u>	34
<u>3.4. Entorno computacional y herramientas utilizadas</u>	34
<u>3.5. Análisis exploratorio de datos.....</u>	34
<u>3.5.1. Revisión de valores nulos o ausentes</u>	34
3.5.2. Exploración de variables categóricas.....	34
3.5.3. Exploración de variables numéricas	47
3.5.4. Análisis de correlaciones	54
<u>3.6. Criterios de inclusión, exclusión y deduplicación</u>	57
3.6.1. Criterios generales de inclusión	58
3.6.2. Criterios generales de exclusión.....	58
3.6.3. Deduplicación de registros	58
<u>3.7. Definición de las variables de supervivencia.....</u>	58
<u>3.8. Selección de covariables para el modelado</u>	59
3.8.1. Covariables seleccionadas en METABRIC	59
3.8.2. Covariables seleccionadas en TCGA-BRCA	60
3.8.3. Covariables seleccionadas en MSK-NSCLC	60
<u>3.9. Preprocesamiento de datos</u>	61
3.9.1. División en conjuntos de entrenamiento y prueba.....	61
3.9.2. Imputación de valores ausentes.....	61
3.9.3. Tratamiento de valores extremos	61
3.9.4. Codificación de variables categóricas.....	62
3.9.5. Escalado de variables numéricas.....	62
3.9.6. Conversión a formatos compatibles con modelos de supervivencia.....	62
<u>3.10. Modelos de supervivencia implementados</u>	62
3.10.1. Estimador de Kaplan-Meier	63
3.10.2. Modelo de Cox penalizado	63
3.10.3. Random Survival Forest.....	63
3.10.4. DeepSurv	64

3.11. Estrategia de validación	65
3.12. Métricas de evaluación	65
3.13. Estrategia de interpretabilidad	65
CAPÍTULO 4. RESULTADOS	65
4.1. Introducción al capítulo.....	66
4.2. Características finales de las cohortes analizadas	66
4.3. Supervivencia global mediante Kaplan-Meier	66
4.4. Comparación univariante de supervivencia mediante test log-rank.....	67
4.5. Resultados del modelo Cox-LASSO	68
4.6. Resultados de la búsqueda de hiperparámetros	68
4.8. Comparación global del rendimiento de los modelos	69
4.9. Estratificación de riesgo mediante modelos principales	71
4.11. Interpretabilidad de los modelos principales	72
4.11.1. Interpretabilidad del modelo RSF en METABRIC.....	73
4.11.2. Interpretabilidad del modelo DeepSurv en TCGA-BRCA	74
4.11.3. Interpretabilidad del modelo DeepSurv en TCGA-BRCA	74
4.12. Validación externa cruzada entre METABRIC y TCGA-BRCA.....	75
4.12.1. Validación externa 1: METABRIC -> TCGA-BRCA con RSF	75
4.12.2. Validación externa 2: TCGA-BRCA → METABRIC con DeepSurv	76
Referencias bibliográficas	78

LISTA DE TABLAS

<i>Tabla 1. Principales conjuntos de datos oncológicos de acceso público y controlado utilizados en investigación biomédica, con información sobre su organismo fuente, tipo de datos, tamaño muestral aproximado, modalidad de acceso y principales ventajas.</i>	<i>3</i>
<i>Tabla 2. Fases del flujo metodológico del estudio, desde la adquisición y preprocesamiento de datos hasta el modelado de supervivencia, evaluación, interpretabilidad y análisis comparativo entre conjuntos de datos oncológicos.</i>	<i>7</i>
<i>Tabla 3. Planificación temporal del proyecto, detallando las fases del TFM, sus tareas principales, entregables asociados, hitos académicos y duración estimada desde la definición inicial hasta la entrega final.....</i>	<i>9</i>
<i>Tabla 4. Matriz de riesgos del proyecto, que identifica las principales amenazas técnicas y metodológicas, su probabilidad e impacto, junto con los planes de mitigación y contingencia asociados.</i>	<i>12</i>
<i>Tabla 5. Síntesis de estudios clave en análisis de supervivencia de cáncer de mama con datos genómicos.</i>	<i>23</i>
<i>Tabla 6. Síntesis de estudios clave en análisis de supervivencia de cáncer de pulmón no microcítico con datos genómicos.....</i>	<i>25</i>
<i>Tabla 7. Cuadro resumen de las técnicas y líneas de investigación analizadas en el Capítulo 2: características metodológicas, referencias fundacionales y relevancia para el TFM.</i>	<i>29</i>
<i>Tabla 8. Características principales de las cohortes utilizadas en el estudio.....</i>	<i>32</i>

Tabla 10. División train/test por cohorte.....	61
Tabla 11. Distribución final de eventos de supervivencia por cohorte.	66
Tabla 12. Resumen del test log-rank por cohorte. Las variables significativas presentan un p-value < 0.05.	68
Tabla 13. Variables principales seleccionadas por Cox-LASSO por cohorte. Las variables	68
Tabla 14. Hiperparámetros seleccionados para Random Survival Forest por cohorte.	69
Tabla 15. Arquitectura e hiperparámetros seleccionados para DeepSurv por cohorte.	69
Tabla 16. Mejor modelo por cohorte según C-index e IBS en test.	70
Tabla 17. Resultados de validación externa cruzada entre METABRIC y TCGA-BRCA.	77

LISTA DE FIGURAS

Figura 1. Diagrama de Gantt del cronograma del TFM, que muestra la planificación temporal de las fases del proyecto (definición y estado del arte, adquisición y preprocesamiento, implementación de modelos, análisis y validación, y redacción), con sus fechas de inicio, duración estimada y fecha de finalización.	11
Figura 2. Evolución cronológica de los principales métodos de análisis de supervivencia oncológica, desde el estimador de Kaplan-Meier (1958) hasta los modelos de aprendizaje profundo multimodal (2021+). Los colores distinguen las familias metodológicas: azul (métodos clásicos), verde (machine learning/aprendizaje automatico), naranja (datos genómicos) y morado (deep learning/aprendizaje profundo).	18
Figura 3. Pipeline metodológico del análisis de supervivencia genómico propuesto en el TFM. El flujo muestra las etapas desde la adquisición de datos de TCGA y METABRIC hasta la evaluación mediante métricas estándar, con los mecanismos de validación cruzada interna (k-fold) y validación externa cruzada entre conjuntos de datos.	20
Figura 4. Rangos de C-index reportados en la literatura por familia metodológica para modelos de supervivencia aplicados a cáncer de mama y pulmón sobre TCGA y/o METABRIC. Las barras muestran el valor medio y las líneas de error el rango mínimo-máximo reportado en los estudios revisados. La línea roja discontinua marca el nivel de rendimiento aleatorio (C-index =0.50).	28
Figura 5. Variables identificadoras y metadatos del estudio en METABRIC.	35
Figura 6. Variables sobre el perfil clínico-demográfico y anatómico en METABRIC.	36
Figura 7. Variables sobre la caracterización histológica y patológica en METABRIC.	36
Figura 8. Variables sobre biomarcadores Moleculares y Subtipos en METABRIC.	37
Figura 9. Variables sobre intervenciones terapéuticas en METABRIC.	38
Figura 10. Variables del estado de supervivencia en METABRIC.	38
Figura 11. Variables identificadoras y metadatos del estudio en TCGA-BRCA.	40
Figura 12 Variables sobre el Perfil clínico-demográfico y anatómico en TCGA-BRCA	41
Figura 13. Variables sobre la Caracterización histológica y estadificación AJCC en TCGA-BRCA.	42
Figura 14. Variables del estado de supervivencia en TCGA-BRCA	43
Figura 15. Variables identificadoras y metadatos del estudio en MSK-NSCLC.	43
Figura 16. Variables sobre el perfil clínico-demográfico y anatómico en MSK-NSCLC.	44
Figura 17. Variables sobre la Clasificación patológica y diagnóstica en MSK-NSCLC.	45
Figura 18. Variables sobre la localización y naturaleza de la muestra en MSK_NSCLC.	46
Figura 19. Variables sobre la Metodología y calidad genómica en MSK-NSCLC.	46
Figura 20. Variable objetivo y tratamiento en MSK-NSCLC.	47
Figura 21. Variables sobre la demografía y contexto de la cohorte en METABRIC.	47
Figura 22. Variables sobre parámetros clínico-patológicos en METABRIC.	48
Figura 23. Métricas de agresividad molecular en METABRIC.	49
Figura 24. Métricas de Supervivencia en METABRIC.	49
Figura 25. Variables de Estructura Muestral en TCGA-BRCA.....	50
Figura 26. Variables sobre la Demografía y diagnóstico en TCGA-BRCA.....	51
Figura 27. Métricas de agresividad molecular en TCGA-BRCA.	52
Figura 28. Métricas de supervivencia en TCGA-BRCA.....	52
Figura 29. Variables de Granularidad del seguimiento en MSK-NSCLC.	53
Figura 30. Variables sobre la carga genómica y estabilidad molecular en MSK-NSCLC.	53
Figura 31. Variables sobre la carga tumoral física y estadificación en MSK-NSCLC.	54

<i>Figura 32. Métricas de supervivencia y tiempo en MSK-NSCLC.....</i>	<i>54</i>
<i>Figura 33. Mapa de calor de correlaciones de las variables numéricas en METABRIC.....</i>	<i>55</i>
<i>Figura 34. Mapa de calor de correlaciones de las variables numéricas en TCGA_BRCA.</i>	<i>56</i>
<i>Figura 35. Mapa de calor de correlaciones de las variables numéricas en MSK-NSCLC.</i>	<i>57</i>
<i>Figura 36. Arquitectura del modelo DeepSurv, ejemplo en TCGA-BRCA.</i>	<i>64</i>
<i>Figura 37. Curvas de Kaplan-Meier globales no estratificadas de las tres cohortes: METABRIC (Arriba), TCGA-BRCA (En medio) y MSK-NSCLC (Abajo).</i>	<i>67</i>
<i>Figura 38. Comparación del C-index e IBS en test entre Cox-LASSO, Random Survival Forest y DeepSurv por cohorte.</i>	<i>70</i>
<i>Figura 39. Top 25 variables según permutation importance del modelo Random Survival Forest en METABRIC.</i>	<i>74</i>
<i>Figura 40. Top 3 variables segun SHAP del modelo DeepSurv en TCGA-BRCA.</i>	<i>74</i>
<i>Figura 41. Top 25 variables según permutation importance del modelo Random Survival Forest en MSK_NSCLC..</i>	<i>75</i>
<i>Figura 42. Validación externa METABRIC → TCGA-BRCA mediante Random Survival Forest. Curvas de Kaplan-Meier en la cohorte externa TCGA-BRCA tras entrenar el modelo en METABRIC. Se muestra la estratificación de pacientes en grupos de bajo y alto riesgo, así como por cuartiles de riesgo estimado. ...</i>	<i>76</i>
<i>Figura 43. Validación externa TCGA-BRCA -> METABRIC mediante Random Survival Forest. Curvas de Kaplan-Meier en la cohorte externa TCGA-BRCA tras entrenar el modelo en METABRIC. Se muestra la estratificación de pacientes en grupos de bajo y alto riesgo, así como por cuartiles de riesgo estimado. ...</i>	<i>77</i>

CAPÍTULO 1: INTRODUCCIÓN

1.1 Contexto y justificación del trabajo

1.1.1 Situación actual de la supervivencia en cáncer

El cáncer constituye uno de los mayores retos de salud pública del siglo XXI. Según los datos publicados por la Agencia Internacional para la Investigación sobre el Cáncer (IARC) en el informe GLOBOCAN 2022 (Bray et al., 2024), se diagnosticaron en ese año aproximadamente 20 millones de nuevos casos de cáncer en todo el mundo, con una mortalidad asociada de casi 10 millones de personas. En España, el cáncer se situó como la primera causa de muerte en 2025, por detrás de las enfermedades cardiovasculares, y es la primera causa de años de vida potencialmente perdidos (Datos del INE en 2024). A pesar de los avances significativos en el diagnóstico y tratamiento oncológico producidos durante las últimas décadas (Banerjee et al., 2024), la supervivencia global a cinco años continúa siendo heterogénea y altamente dependiente del tipo tumoral, del estadio en el momento del diagnóstico, de las características biológicas del tumor y de los factores individuales del paciente.

El cáncer de mama y el cáncer de pulmón son, respectivamente, el cáncer con mayor incidencia en mujeres y el de mayor mortalidad en ambos sexos a nivel mundial (Bray et al., 2024). En el cáncer de mama, la supervivencia relativa a cinco años supera el 90% en estadios localizados, pero cae dramáticamente por debajo del 30% en estadios metastásicos. El cáncer de pulmón, cuya supervivencia global a cinco años se sitúa en torno al 19-22%, presenta una heterogeneidad molecular y clínica enorme que condiciona de forma crítica el pronóstico y la respuesta al tratamiento. Estas características hacen de ambos tipos ideales para el desarrollo de modelos predictivos basados en perfiles genómicos.

1.1.2 Relevancia del análisis de supervivencia en oncología

El análisis de supervivencia constituye el conjunto de técnicas estadísticas diseñadas para modelar el tiempo hasta la ocurrencia de un evento de interés, habitualmente la muerte del paciente o la recurrencia tumoral (Le-Rademacher & Wang, 2021). A diferencia de los modelos de regresión convencionales, el análisis de supervivencia incorpora de forma nativa el fenómeno de la censura, es decir, la situación en que un sujeto abandona el estudio antes de experimentar el evento o el seguimiento finaliza sin que este se haya producido (Usman et al., 2014). Esta capacidad resulta imprescindible en estudios longitudinales oncológicos, en los que la censura es inevitable y su tratamiento incorrecto introduce sesgos graves en las estimaciones pronósticas.

Desde su introducción en la década de 1950, los métodos de análisis de supervivencia han evolucionado considerablemente. El estimador no paramétrico de Kaplan-Meier (Kaplan & Meier, 1958) sigue siendo el estándar de referencia para la descripción gráfica de curvas de supervivencia en grupos de pacientes. El modelo de riesgos proporcionales de Cox (Cox, 1972) introdujo la posibilidad de ajustar el efecto de múltiples covariables simultáneamente, convirtiéndose en el modelo más utilizado en la literatura clínica. Sin

embargo, la creciente disponibilidad de datos genómicos de alta dimensionalidad (con decenas de miles de variables por paciente) ha impulsado el desarrollo de métodos más potentes, capaces de capturar relaciones no lineales y de manejar espacios de características de alta dimensión.

1.1.3 Papel de los factores genéticos en el pronóstico oncológico

La genómica ha transformado profundamente la comprensión del cáncer (Molla & Bitew, 2025). La secuenciación masiva del genoma tumoral ha revelado que los tumores, incluso del mismo tipo histológico, presentan perfiles moleculares radicalmente distintos que condicionan de forma determinante su comportamiento biológico, su agresividad y su respuesta a los tratamientos. En el cáncer de mama, la clasificación molecular en subtipos intrínsecos (Luminal A, Luminal B, HER2-enriched y Triple Negativo) ha demostrado tener mayor valor pronóstico que la estadificación TNM convencional (Orrantia-Borunda et al., 2022). En el cáncer de pulmón no microcítico, la identificación de mutaciones en EGFR, ERBB2 o KRAS tiene implicaciones directas en la selección del tratamiento dirigido (Cardarella & Johnson, 2013).

La integración de datos de expresión génica, mutaciones somáticas, variaciones en el número de copias (CNV) y metilación del ADN en modelos predictivos de supervivencia ha demostrado mejorar significativamente la capacidad pronóstica respecto a los modelos basados exclusivamente en variables clínicas (Tong et al., 2020). No obstante, el análisis de este tipo de datos multimodales presenta desafíos metodológicos sustanciales, entre los que destacan la alta dimensionalidad, la colinealidad entre variables (Zhao et al., 2015), el desequilibrio entre el número de eventos y el tamaño muestral (Nguyen & Vafaei, 2025), y la necesidad de validación externa en cohortes independientes (Ramspek et al., 2021).

1.1.4 Limitaciones actuales en modelos predictivos

A pesar del notable progreso experimentado en los últimos años, los modelos predictivos de supervivencia oncológica presentan limitaciones importantes que justifican nuevas investigaciones en el campo. En primer lugar, muchos modelos publicados en la literatura han sido entrenados y validados sobre un único conjunto de datos, sin comprobación de su capacidad de generalización en cohortes independientes (Li et al., 2021), lo que introduce riesgos de sobreajuste amplificados por prácticas metodológicas como la selección supervisada de variables fuera del marco de muestreo (Clarke et al., 2008). En segundo lugar, la interpretabilidad de los modelos de aprendizaje automático más complejos (como las redes neuronales profundas) sigue siendo un reto pendiente, con implicaciones directas en la adopción clínica de estas herramientas (Abbas et al., 2025). En tercer lugar, la heterogeneidad en los protocolos de recogida y codificación de datos entre distintos repositorios dificulta la armonización y el análisis conjunto de cohortes diversas (Han et al., 2025), siendo especialmente relevante en el caso de TCGA y METABRIC, que emplean plataformas de perfilado molecular distintas (Bismeyer et al., 2018).

El presente TFM aborda explícitamente estas limitaciones al proponer un diseño metodológico que incorpora dos conjuntos de datos independientes (TCGA y METABRIC), aplica múltiples familias de modelos con distinto nivel de complejidad e interpretabilidad,

e implementa protocolos rigurosos de validación cruzada y evaluación mediante métricas estandarizadas.

1.1.5 Propuesta concreta de tipos de cáncer y justificación

Aunque el análisis de supervivencia puede aplicarse a cualquier tipo de cáncer, la amplitud del enfoque genómico exige una delimitación precisa del objeto de estudio. Se propone centrar el análisis en dos tipos de cáncer con características complementarias:

Cáncer de mama (*breast cancer*): presenta la mayor disponibilidad de datos genómicos públicos de alta calidad (TCGA-BRCA, METABRIC), una clasificación molecular bien establecida y una extensa literatura de referencia para la comparación de resultados (Curtis et al., 2012; Li et al., 2021; Sørlie et al., 2001). La elevada incidencia y la variabilidad pronóstica entre subtipos moleculares lo convierten en un caso paradigmático para el análisis de supervivencia basado en genómica.

Cáncer de pulmón no microcítico (NSCLC – Non-Small Cell Lung Cancer): presenta la mayor mortalidad oncológica mundial (Bray et al., 2024), elevada heterogeneidad molecular, y una disponibilidad adecuada de datos. El contraste entre sus subtipos histológicos (adenocarcinoma vs. carcinoma escamoso) añade valor analítico al estudio comparativo (Cardarella & Johnson, 2013).

La elección de cáncer de mama como foco primario se justifica por la superior disponibilidad y calidad de datos, en particular la cohorte METABRIC (n > 2.000 pacientes con seguimiento largo), que permite una validación cruzada externa robusta. El cáncer de pulmón actuará como tipo secundario de análisis, permitiendo evaluar la transferibilidad metodológica del enfoque.

1.1.6 Conjuntos de datos propuestos – Tabla comparativa

La tabla 1 resume los principales conjuntos de datos utilizados en este trabajo, incluyendo información sobre su organismo de procedencia, el tipo de datos disponibles, el tamaño aproximado de la muestra y las condiciones de acceso. Asimismo, se destacan las ventajas más relevantes de cada fuente, especialmente en términos de riqueza de información y aplicabilidad en estudios de supervivencia.

Tabla 1. Principales conjuntos de datos oncológicos de acceso público y controlado utilizados en investigación biomédica, con información sobre su organismo fuente, tipo de datos, tamaño muestral aproximado, modalidad de acceso y principales ventajas.

Conjunto de datos	Organismo / Fuente	Tipo de datos	N aprox.	Acceso	Ventajas principales
TCGA (The Cancer Genome Atlas)	NCI / NIH (EE.UU.)	Expresión génica, mutaciones, CNV, metilación, clínico	>11.000 pacientes, >30 tipos de cáncer	Público (GDC Portal)	Multimodal, estándar de referencia en la literatura
METABRIC (Molecular Taxonomy of Breast Cancer International Consortium)	UK	Microarrays expresión génica, CNV, clínico	>2.000 pacientes (cáncer mama) de	Público (cBioPortal / EGA)	Gran seguimiento, subtipos moleculares validados

TCIA (The Cancer Imaging Archive)	NCI / NIH (EE.UU.)	Datos de imágenes por tipo de cancer	>11.000 pacientes, >30 tipos de cáncer	Público (GDC Portal)	Multimodal, estándar de referencia en la literatura
UK Biobank	MRC / Wellcome Trust (UK)	Genómica (GWAS), clínico, imágenes	>500.000 participantes	Controlado (previa solicitud)	Muy representativo

Para este TFM se propone la combinación TCGA + METABRIC como estrategia más viable, dado que ambos están disponibles de forma pública o semipública, están ampliamente documentados en la literatura y presentan solapamiento parcial de variables que facilitará el análisis comparativo e integrado.

1.2 Objetivos del trabajo

1.2.1 Objetivo general

Desarrollar, comparar y validar modelos de análisis de supervivencia basados en datos genómicos para la predicción del pronóstico oncológico en cáncer de mama y cáncer de pulmón, utilizando dos cohortes independientes (TCGA y METABRIC), con el fin de identificar las metodologías con mayor capacidad predictiva y generalización entre conjuntos de datos.

1.2.2 Objetivos específicos

1. Implementar y entrenar al menos cuatro modelos de análisis de supervivencia (Kaplan-Meier, regresión de Cox penalizada (LASSO), Random Survival Forest (RSF) y DeepSurv) sobre datos genómicos de las cohortes seleccionadas, documentando las decisiones de diseño y los hiperparámetros adoptados en cada caso.
2. Evaluar y comparar el rendimiento predictivo de los modelos implementados mediante métricas estándar (C-index, Brier Score integrado y log-rank test), aplicando validación cruzada k-fold para controlar el sobreajuste y estimar la varianza del rendimiento.
3. Analizar la transferibilidad y robustez de los modelos mediante validación externa cruzada entre las cohortes TCGA y METABRIC, identificando diferencias de rendimiento atribuibles a la heterogeneidad entre conjuntos de datos.
4. Adquirir, preprocesar e integrar los datos genómicos y clínicos procedentes de las cohortes TCGA-BRCA, MSK_NSLC y METABRIC, garantizando la calidad, coherencia y trazabilidad del proceso de preparación de datos.
5. Identificar los factores genómicos y tipo de cáncer con mayor relevancia predictiva mediante técnicas de interpretabilidad para los modelos principales de cada cohorte (importancia de variables en RSF, coeficientes de Cox, análisis SHAP en DeepSurv), contrastando los resultados con la literatura científica de referencia.
6. Revisar el estado del arte en análisis de supervivencia oncológica con datos genómicos, identificando los modelos más utilizados, sus fundamentos teóricos y sus limitaciones metodológicas documentadas, como marco de comparación para los resultados obtenidos.

7. Producir un repositorio de código público (GitHub) con todos los scripts, pipelines de preprocesamiento, notebooks de análisis y visualizaciones generados durante el TFM, siguiendo estándares de reproducibilidad (FAIR).
8. Reflexionar críticamente sobre las limitaciones del trabajo, los sesgos derivados del uso de cohortes no representativas y las líneas de investigación futura que pueden derivarse de los hallazgos obtenidos.

1.3 Impacto en sostenibilidad, ético-social y diversidad

1.3.1 Impacto ético del uso de datos genéticos

El uso de datos genómicos en investigación biomédica plantea desafíos éticos de especial envergadura. A diferencia de los datos clínicos convencionales, los datos genéticos son inherentemente únicos y en principio irrevocablemente vinculados al individuo. Su análisis puede revelar información sensible no solo sobre el sujeto directamente estudiado, sino también sobre sus familiares biológicos, lo que amplía el perímetro de privacidad afectado más allá del paciente individual. En el contexto de un TFM basado exclusivamente en conjuntos de datos públicos y previamente anonimizados, estos riesgos se minimizan, pero no desaparecen por completo.

En particular, es relevante considerar el riesgo de reidentificación. La combinación de datos genómicos con variables fenotípicas o clínicas puede, en ciertos contextos, permitir identificar a individuos específicos incluso cuando los identificadores directos han sido eliminados. Estudios como el de (Gymrek et al., 2013) han demostrado que la reidentificación de sujetos a partir de datos genómicos supuestamente anónimos es técnicamente posible, lo que subraya la necesidad de adoptar medidas adicionales de protección más allá de la simple eliminación de campos identificadores.

1.3.2 Protección de datos y privacidad

El presente trabajo se realizará íntegramente sobre datos de acceso público o de acceso controlado previamente concedido por las instituciones custodias (en el caso de datos de acceso controlado en GDC). En ningún caso se recopilarán, procesarán ni almacenarán datos de pacientes de forma directa. No obstante, se seguirán estrictamente los principios del Reglamento General de Protección de Datos (RGPD, Reglamento UE 2016/679) y las directrices de la Ley Orgánica 3/2018 de Protección de Datos Personales y Garantía de los Derechos Digitales (LOPDGDD).

1.3.3 Sesgos en conjuntos de datos biomédicos y equidad sanitaria

Una limitación estructural relevante en los grandes repositorios genómicos públicos es la sobrerrepresentación de poblaciones de ancestría europea en detrimento de otras etnias. Los conjuntos de datos TCGA y METABRIC, aunque de gran valor científico, presentan esta característica. Esta falta de diversidad poblacional puede introducir sesgos en los modelos entrenados, cuya capacidad predictiva puede no generalizarse adecuadamente a pacientes de otras ancestrías. Este sesgo tiene implicaciones directas en la equidad sanitaria. Por ejemplo, si los modelos de predicción pronóstica son menos fiables para ciertas poblaciones, su adopción clínica puede acentuar las desigualdades en el acceso a un diagnóstico y tratamiento precisos.

En el marco de este TFM se abordará esta limitación de forma explícita, documentando la composición étnica de los conjuntos de datos utilizados y discutiendo el alcance de los resultados en función de esta característica.

1.3.4 Relevancia social del trabajo

El desarrollo de herramientas de predicción de supervivencia oncológica con base genómica tiene un impacto social potencialmente elevado. En el corto plazo, puede contribuir a una mejor estratificación del riesgo en el momento del diagnóstico, facilitando la personalización de los tratamientos y la priorización de recursos en sistemas de salud con capacidad limitada. En el medio y largo plazo, el avance en este campo puede contribuir a reducir la mortalidad por cáncer mediante una detección más temprana de perfiles de alto riesgo y una selección más precisa de las intervenciones terapéuticas.

Desde el punto de vista de la sostenibilidad, el trabajo tiene un impacto ambiental limitado al uso de recursos computacionales en la nube o en infraestructura universitaria. No obstante, se contempla la optimización del consumo computacional mediante el uso eficiente de algoritmos y la reutilización de representaciones intermedias de datos (*embeddings*, preprocesados cacheados).

1.3.5 Protocolo ético y protección de datos

El protocolo ético del presente TFM se basa en los siguientes principios y medidas concretas:

- RGPD y normativa aplicable: El trabajo se enmarca en el uso secundario de datos de investigación previamente anonimizados y recopilados con el consentimiento informado de los participantes en sus estudios de origen. El tratamiento de estos datos respeta los principios de minimización, finalidad y limitación del almacenamiento establecidos por el RGPD.
- Anonimización: Los conjuntos de datos TCGA y METABRIC utilizan identificadores pseudoanónimos (códigos alfanuméricos) en lugar de nombres, fechas de nacimiento exactas u otros datos directamente identificativos. El TFM no realizará ningún intento de reidentificación de sujetos y los identificadores internos de los conjuntos de datos no serán publicados ni compartidos fuera del entorno de investigación.
- Uso de conjuntos de datos públicos: TCGA es accesible de forma abierta para datos no controlados a través del GDC Data Portal, y de forma controlada (previo acuerdo de acceso) para ciertos tipos de datos. METABRIC está disponible a través de cBioPortal para uso no comercial. En ambos casos, el acceso a los datos se realizará cumpliendo estrictamente los términos y condiciones de uso establecidos por las instituciones custodias.
- Buenas prácticas en ciencia de datos biomédica: Se seguirán las directrices FAIR (*Findable, Accessible, Interoperable, Reusable*) para la gestión de datos y código. El repositorio de código será público, pero no incluirá datos de pacientes. Se utilizará control de versiones (Git) y se documentarán exhaustivamente todas las decisiones de preprocesamiento y modelado.

1.4 Enfoque y método seguido

1.4.1 Tipo de estudio

El presente trabajo corresponde a un estudio observacional retrospectivo basado en análisis secundario de datos. No se realizará ninguna intervención sobre sujetos ni se recopilarán nuevos datos. El diseño analítico es de cohorte histórica: se parte de conjuntos de datos de pacientes oncológicos con seguimiento conocido, y se modela el tiempo hasta el evento (muerte, recurrencia) en función de los perfiles genómicos y variables clínicas disponibles.

1.4.2 Pipeline metodológico

La tabla 2 presenta de forma estructurada el flujo metodológico seguido en el desarrollo del trabajo, organizado en distintas fases que abarcan desde la adquisición de los datos hasta el análisis comparativo entre conjuntos de datos. Para cada etapa, se describen las actividades principales realizadas, junto con las herramientas y librerías empleadas en cada caso.

Tabla 2. Fases del flujo metodológico del estudio, desde la adquisición y preprocesamiento de datos hasta el modelado de supervivencia, evaluación, interpretabilidad y análisis comparativo entre conjuntos de datos oncológicos.

Fase	Etapas	Actividades principales	Herramientas / Librerías
1	Adquisición de datos	Descarga de conjuntos de datos TCGA y METABRIC; selección de variables relevantes (expresión génica, mutaciones, CNV, variables clínicas de supervivencia)	GDC Data Transfer Tool, cBioPortal API, TCGAbiolinks (R/Python)
2	Preprocesamiento y calidad	Filtrado de genes de baja varianza, normalización, imputación de valores ausentes, selección de características (PCA)	Python (pandas, numpy, scikit-learn, ...)
3	Análisis exploratorio (EDA)	Distribución de variables clínicas, tasas de eventos, análisis de censura, correlaciones entre expresión génica y supervivencia	matplotlib, seaborn, plotly lifelines (Python)
4	Modelado de supervivencia	Implementación de Kaplan-Meier, Cox PH, RSF y DeepSurv; ajuste de hiperparámetros mediante búsqueda en rejilla o Bayesiana	scikit-learn, scikit-survival, pycox, PyTorch / TensorFlow
5	Evaluación y validación	C-index, Brier Score, log-rank test; validación cruzada k-fold (k=5 o k=10); validación externa cruzando conjuntos de datos	scikit-survival, scikit-learn, scipy.stats
6	Interpretabilidad y análisis de importancia	Extracción de variables más relevantes; comparación con literatura genómica	RSF feature importance, coeficientes Cox
7	Análisis comparativo inter-dataset	Transferencia de modelos entre TCGA y METABRIC; análisis de diferencias en rendimiento; discusión de causas	Python, tablas comparativas, visualizaciones

1.4.3 Técnicas de análisis de supervivencia

Se describen a continuación las técnicas metodológicas que se implementarán en el trabajo:

- Estimador de Kaplan-Meier: Método no paramétrico para la estimación de la función de supervivencia a partir de datos censurados. Se utilizará para la descripción inicial de las curvas de supervivencia por grupos (subtipos

moleculares, estadios) y para la visualización de diferencias entre cohortes mediante el test log-rank.

- Modelo de riesgos proporcionales de Cox (Cox PH): Modelo semiparamétrico que modela la tasa de riesgo instantánea (hazard) como producto de una función basal no especificada y una función exponencial de las covariables. Permite estimar el efecto relativo de cada variable genómica sobre el riesgo de evento. Se explorará la regularización mediante penalización LASSO para el manejo de alta dimensionalidad.
- Random Survival Forest (RSF): Extensión del algoritmo de bosque aleatorio al contexto de supervivencia, basada en la construcción de múltiples árboles de supervivencia mediante la función de log-rank como criterio de división. Permite capturar relaciones no lineales e interacciones entre variables sin necesidad de asumir proporcionalidad de los riesgos.
- DeepSurv: Red neuronal profunda de tipo *feedforward* que minimiza la función de pérdida de verosimilitud parcial de Cox. Permite modelar relaciones altamente no lineales entre las variables de entrada y el riesgo de evento, ofreciendo mayor flexibilidad a costa de mayor complejidad de entrenamiento e interpretabilidad reducida.

1.4.4 Métricas de evaluación

Se utilizarán las siguientes métricas para la evaluación y comparación de modelos:

- C-index (*Concordance Index*): Mide la probabilidad de que, dado un par de pacientes, el modelo asigne un riesgo mayor al que experimenta el evento primero. Equivalente al área bajo la curva ROC para datos de supervivencia. Valores próximos a 1 indican discriminación excelente; valores cercanos a 0,5 indican rendimiento similar al azar.
- Brier Score integrado (IBS): Mide el error cuadrático medio de la probabilidad de supervivencia estimada respecto al resultado real observado, integrado sobre el horizonte temporal de seguimiento. Proporciona una medida de calibración y discriminación conjunta.
- Log-rank test: Test estadístico no paramétrico para la comparación de curvas de supervivencia entre grupos. Se utilizará para evaluar si las diferencias en supervivencia entre subgrupos definidos por perfil genómico o por conjunto de datos son estadísticamente significativas.

1.5 Planificación del trabajo

1.5.1 Fases, tareas, entregables e hitos

La tabla 3 recoge la planificación temporal del trabajo, estructurada en cinco fases que abarcan desde la definición inicial y revisión del estado del arte hasta la redacción final del TFM. En ella se detallan, para cada fase, las tareas principales a desarrollar, los entregables asociados, así como los hitos que marcan la finalización de cada etapa.

Tabla 3. Planificación temporal del proyecto, detallando las fases del TFM, sus tareas principales, entregables asociados, hitos académicos y duración estimada desde la definición inicial hasta la entrega final.

Fase	Tareas principales	Entregables	Hito	Duración est.
F1 – Definición y estado del arte	Revisión bibliográfica; definición del alcance; selección definitiva de conjuntos de datos y metodología	Capítulo 1 (Introducción) + Capítulo 2 (Estado del arte)	Aprobación del plan por el tutor	Feb – Mar
F2 – Adquisición y preprocesamiento	Descarga de TCGA y METABRIC; limpieza, normalización, reducción dimensional y análisis exploratorio	Capítulo 3 (Datos) + scripts de preprocesamiento	Conjuntos de datos listo para modelado	Abr
F3 – Implementación de modelos	Implementación de KM, Cox, RSF y DeepSurv; ajuste de hiperparámetros; primera evaluación	Capítulo 4 (Metodología) + notebooks de modelos	Modelos entrenados y evaluados	May
F4 – Análisis y validación	Validación cruzada; análisis de importancia de variables; validación externa entre conjuntos de datos	Capítulo 5 (Resultados y discusión) + tablas y figuras	Resultados comparativos completos	May-Jun
F5 – Redacción y revisión	Redacción de Capítulos 6 y 7; revisión integral de la memoria; preparación del repositorio público	Memoria completa (capítulos 1-7) + repositorio GitHub	Entrega formal del TFM	Jun

1.5.2 Diagrama de Gantt con planificación del TFM

La figura 1 muestra el diagrama de Gantt correspondiente a la planificación temporal del trabajo, donde se representan de forma visual las distintas fases del proyecto, su duración y su distribución a lo largo del tiempo. Cada bloque indica el periodo de ejecución de las tareas, permitiendo identificar solapamientos, secuencia de actividades y momentos clave del desarrollo.




Figura 1. Diagrama de Gantt del cronograma del TFM, que muestra la planificación temporal de las fases del proyecto (definición y estado del arte, adquisición y preprocesamiento, implementación de modelos, análisis y validación, y redacción), con sus fechas de inicio, duración estimada y fecha de finalización.

1.5.3 Tabla de riesgos y mitigaciones

La tabla 4 recoge los principales riesgos identificados a lo largo del desarrollo del trabajo, junto con una estimación de su probabilidad e impacto, así como las estrategias de mitigación y los planes de contingencia asociados. Este análisis permite anticipar posibles dificultades tanto técnicas como organizativas, abarcando aspectos relacionados con los datos, el modelado y la propia redacción de la memoria.

Tabla 4. Matriz de riesgos del proyecto, que identifica las principales amenazas técnicas y metodológicas, su probabilidad e impacto, junto con los planes de mitigación y contingencia asociados.

Riesgo identificado	Probabilidad	Impacto	Plan de mitigación	Plan de contingencia
Problemas de acceso o descarga de datos (TCGA/METABRIC)	Media	Alto	Consultar pre-documentación oficial; usar herramientas de descarga alternativas (TCGAbiolinks, cBioPortal API)	Usar versión pre-procesada disponible en repositorios de referencia (Synapse, GEO)
Alta dimensionalidad que dificulte convergencia de modelos	Alta	Medio	Aplicar reducción dimensional previa (PCA, LASSO, selección por varianza)	Limitar el análisis a un subconjunto de genes validados en la literatura
Bajo número de eventos en algún conjunto de datos (pocos fallecimientos registrados)	Media	Alto	Verificar tasas de evento antes de comenzar el análisis; ajustar el horizonte temporal de seguimiento	Combinar endpoints (muerte + recurrencia); o enfocar el análisis en supervivencia libre de enfermedad
Tiempo de entrenamiento excesivo para modelos de deep learning	Media	Medio	Usar GPU de Google Colab Pro / Kaggle Notebooks; limitar número de épocas y usar early stopping	Simplificar la arquitectura de DeepSurv o priorizar RSF como modelo complejo principal
Divergencia metodológica entre TCGA y METABRIC que dificulte la comparación	Media	Medio	Documentar diferencias en protocolos de recogida; realizar análisis de batch effect	Centrar el análisis comparativo en variables comunes y bien caracterizadas en ambos conjuntos de datos
Dificultades en la redacción y estructura de la memoria	Baja	Medio	Seguir la estructura definida en este Capítulo 1; mantener reuniones regulares con el tutor	Usar plantillas académicas y ejemplos de TFM anteriores aprobados en el máster

1.6 Breve resumen de productos obtenidos

El presente TFM generará los siguientes productos concretos y verificables:

- Modelos de supervivencia entrenados: Se obtendrán al menos cuatro modelos entrenados y evaluados (Kaplan-Meier, Cox PH, Random Survival Forest y DeepSurv) sobre dos conjuntos de datos (TCGA y METABRIC), para un total de hasta ocho configuraciones evaluadas. Los modelos serán serializados (formato pickle o similar) para su reproducibilidad.
- Código reproducible y documentado: Se desarrollará un repositorio GitHub que incluirá scripts de preprocesamiento, notebooks de análisis exploratorio, implementación de modelos, evaluación y visualización. El repositorio seguirá estándares de reproducibilidad (requirements.txt, entornos conda/pip, instrucciones claras de ejecución).
- Análisis comparativo entre modelos y conjuntos de datos: Se producirá un análisis sistemático que compare el rendimiento de cada modelo en términos de C-index, Brier Score y log-rank test, tanto dentro de cada conjunto de datos (validación cruzada interna) como entre conjuntos de datos (validación externa cruzada).
- Visualizaciones: Se generarán curvas de Kaplan-Meier estratificadas, gráficos de importancia de variables, mapas de calor de correlaciones genómicas, curvas de calibración y gráficos comparativos de métricas de evaluación. Se buscará que todas las figuras sean reproducibles desde el repositorio.
- Repositorio público (GitHub): Además del código, el repositorio incluirá la documentación técnica del proyecto (README extendido), los archivos de configuración y las instrucciones para reproducir los resultados. Los datos no serán incluidos directamente por motivos de licencia, pero se indicarán las instrucciones para su descarga.
- Memoria académica completa (TFM): El producto central del trabajo será la memoria escrita, estructurada en siete capítulos, que documentará de forma rigurosa todo el proceso de investigación, desde la justificación hasta las conclusiones y las recomendaciones para trabajos futuros.

1.7 Breve descripción de los otros capítulos

La memoria del TFM se organiza en siete capítulos cuya estructura y contenido se describe a continuación:

- Capítulo 2 – Estado del arte: Este capítulo realizará una revisión sistemática y actualizada de la literatura científica sobre análisis de supervivencia en oncología, con especial atención a los trabajos que incorporan datos genómicos. Se revisarán los fundamentos teóricos de los modelos utilizados, los conjuntos de datos más empleados, las métricas de evaluación estándar y las limitaciones identificadas en estudios previos. Se incluirá una sección específica sobre los avances en modelos de aprendizaje automático y deep learning aplicados a la supervivencia oncológica, con énfasis en DeepSurv, SurvivalNet y arquitecturas de transformers adaptadas al contexto.
- Capítulo 3 – Datos: Este capítulo describirá en detalle los conjuntos de datos utilizados (TCGA y METABRIC), incluyendo su origen, proceso de recogida, variables disponibles, estructura de los datos de supervivencia (tiempo al evento, indicador de censura), y el proceso completo de preprocesamiento y preparación de datos. Se documentarán todas las decisiones de limpieza, normalización, imputación y reducción dimensional, con justificación metodológica de cada elección. Se incluirán estadísticas descriptivas y visualizaciones exploratorias de ambas cohortes.
- Capítulo 4 – Metodología: Este capítulo describirá con máximo detalle el diseño metodológico del estudio, incluyendo la formalización matemática de cada modelo de supervivencia implementado, los criterios de selección de hiperparámetros, los procedimientos de validación cruzada y las métricas de evaluación. Se explicarán las decisiones de diseño adoptadas y su justificación. Se incluirá también la descripción del entorno tecnológico utilizado (lenguajes, librerías, infraestructura computacional).
- Capítulo 5 – Resultados: Este capítulo presentará los resultados empíricos del análisis en forma de tablas, figuras y estadísticas interpretadas. Se presentarán las curvas de supervivencia, las métricas de rendimiento de cada modelo en cada conjunto de datos, los análisis de importancia de variables y los resultados de la validación cruzada interna y externa. La presentación será objetiva y sistemática, reservando la interpretación crítica para el capítulo de discusión.
- Capítulo 6 – Discusión: Este capítulo analizará e interpretará críticamente los resultados obtenidos, comparándolos con los reportados en la literatura científica de referencia. Se discutirán las fortalezas y limitaciones del trabajo, el grado en que se han alcanzado los objetivos planteados, las implicaciones clínicas potenciales de los hallazgos y las líneas de investigación futura más prometedoras derivadas del estudio.
- Capítulo 7 – Conclusiones: Este capítulo sintetizará las principales aportaciones del TFM, respondiendo de forma directa a cada uno de los objetivos específicos planteados en el Capítulo 1. Se presentarán las conclusiones de mayor relevancia científica y metodológica, y se formulará una reflexión final sobre el valor del

trabajo en el contexto de la medicina de precisión oncológica y la ciencia de datos biomédica.

1.8 Declaración sobre uso de inteligencia artificial generativa

Yo Julio Úbeda Quesada, autor del presente Trabajo de Fin de Máster, declaro lo siguiente en relación con el uso de herramientas de inteligencia artificial generativa (en adelante, IAG) durante la elaboración de este trabajo:

- **Uso responsable y transparente:** Durante el proceso de elaboración de este TFM se ha hecho uso de herramientas de IAG (concretamente Claude (Anthropic), ChatGPT (OpenAI) o Gemini (Google)) como apoyo en tareas de escritura académica, revisión estilística, búsqueda de referencias bibliográficas y estructuración del contenido. El uso de estas herramientas ha sido en todo momento consciente, declarado y subordinado al criterio intelectual del autor/a.
- **Validación manual del contenido:** Todo el contenido generado con ayuda de herramientas de IAG ha sido revisado, contrastado, editado y validado manualmente por el autor. En ningún caso se ha aceptado de forma acrítica el *output* de estas herramientas sin verificación. Las referencias bibliográficas sugeridas por herramientas de IAG han sido comprobadas en bases de datos académicas originales (PubMed, Google Scholar, IEEE Xplore u otras) antes de su inclusión en el trabajo.
- **Responsabilidad intelectual final:** El autor asume plena y exclusiva responsabilidad intelectual y académica sobre la totalidad del contenido de este TFM, incluyendo las ideas, argumentaciones, análisis, interpretaciones de resultados y conclusiones presentadas. El uso de herramientas de IAG no exime al autor de dicha responsabilidad, ni traslada la autoría del trabajo a dichas herramientas o a sus desarrolladores.
- **Conformidad con la normativa institucional:** El uso de herramientas de IAG se ha realizado en conformidad con las directrices académicas vigentes en la UOC [20]. En aquellos casos en que la normativa institucional establezca restricciones adicionales o requiera comunicación específica al tutor, el autor declara haber cumplido con dichas obligaciones.

Madrid 01/03/2026

Firmado:

Julio Úbeda Quesada

CAPÍTULO 2: ESTADO DEL ARTE

2.1 Introducción al capítulo

El presente capítulo tiene como objetivo trazar una fotografía actualizada del estado del conocimiento científico en el ámbito del análisis de supervivencia aplicado a la oncología de precisión basada en datos genómicos. Siguiendo la metodología de revisión documental descrita por (Oates, 2022). En su marco de investigación en sistemas de información, se adopta un enfoque de *survey* que sistematiza los trabajos previos más relevantes, identifica las tendencias metodológicas dominantes y localiza las brechas de conocimiento que el presente TFM pretende contribuir a cubrir.

La revisión se estructura en torno a cuatro ejes temáticos fundamentales: (i) la evolución de los métodos de análisis de supervivencia, desde los enfoques clásicos hasta los modelos de aprendizaje profundo; (ii) el papel de los datos genómicos en la predicción del pronóstico oncológico; (iii) el estado específico del arte en cáncer de mama y cáncer de pulmón no microcítico; y (iv) los retos metodológicos abiertos en términos de validación, interpretabilidad y equidad de los modelos.

La búsqueda bibliográfica se realizó principalmente en Google Scholar, PubMed y OpenEvidence, utilizando las siguientes palabras clave en combinaciones variables: survival analysis, cancer prognosis, genomic biomarkers, TCGA, METABRIC, Cox proportional hazards, Random Survival Forest, DeepSurv, breast cancer, lung cancer, machine learning, deep learning. El período de cobertura preferente abarca desde 2010 hasta 2025, con inclusión de referencias fundacionales anteriores.

2.2 Evolución histórica de los métodos de análisis de supervivencia

La figura 2 presenta una línea temporal que ilustra la evolución histórica de los principales métodos de análisis de supervivencia en oncología, desde enfoques clásicos no paramétricos como Kaplan-Meier (1958), pasando por modelos semiparamétricos como el Modelo de Cox (1972) y su regularización L1 en Cox LASSO (1997), hasta la incorporación de técnicas de aprendizaje automático como Random Survival Forest (2008). Asimismo, se destaca el impacto del auge de los datos ómicos con iniciativas como TCGA Pan-Cancer (2013) y la transición hacia modelos de aprendizaje profundo, incluyendo DeepSurv (2018) y enfoques multimodales basados en Transformers multimodales (+ 2021), evidenciando una progresiva sofisticación metodológica orientada a mejorar la predicción y comprensión de la supervivencia en contextos oncológicos complejos.

Evolución histórica de los métodos de análisis de supervivencia oncológica




Figura 2. Evolución cronológica de los principales métodos de análisis de supervivencia oncológica, desde el estimador de Kaplan-Meier (1958) hasta los modelos de aprendizaje profundo multimodal (2021+). Los colores distinguen las familias metodológicas: azul (métodos clásicos), verde (machine learning/aprendizaje automatico), naranja (datos genómicos) y morado (deep learning/aprendizaje profundo).

2.2.1 El estimador de Kaplan-Meier

El estimador no paramétrico de Kaplan y Meier (Kaplan & Meier, 1958) permite calcular la función de supervivencia empírica $S(t)$ a partir de datos con censura, sin asumir ninguna forma paramétrica para la distribución del tiempo de supervivencia. Su representación gráfica escalonada se ha convertido en el estándar universal para comunicar resultados de supervivencia en estudios clínicos. Su limitación fundamental es que no permite ajustar covariables de forma multivariable, lo que lo convierte en un instrumento descriptivo y exploratorio. A pesar de esto, el test log-rank, habitualmente asociado a las curvas de Kaplan-Meier, proporciona una prueba estadística no paramétrica para comparar curvas entre grupos (Le-Rademacher & Wang, 2021).

2.2.2 El modelo de riesgos proporcionales de Cox

El modelo de Cox (Cox, 1972) supuso un avance fundamental al introducir un marco semiparamétrico capaz de modelar simultáneamente el efecto de múltiples covariables sobre la tasa de riesgo, asumiendo que la razón de riesgos entre grupos se mantiene constante a lo largo del tiempo (la suposición de riesgos proporcionales). Su extensión mediante regularización LASSO (Tibshirani, 1997) ha permitido adaptar el modelo a escenarios de alta dimensionalidad, realizando simultáneamente selección de variables y estimación de coeficientes. A pesar de su amplia adopción, el modelo de Cox no captura interacciones entre variables ni relaciones no lineales entre marcadores genómicos y el riesgo de evento, limitando su capacidad predictiva en contextos moleculares complejos (Stensrud & Hernán, 2020).

2.3 Métodos de aprendizaje automático para análisis de supervivencia

2.3.1 Motivación del enfoque de machine learning

La irrupción de los datos genómicos de alta dimensionalidad planteó desafíos que los modelos clásicos no podían abordar eficientemente. Con decenas de miles de variables por paciente y cohortes de tamaño moderado, el espacio $D \gg n$ (fenómeno de alta dimensionalidad) provoca sobreajuste y baja generalización en modelos convencionales (Clarke et al., 2008). La extensión de los algoritmos de *machine learning* al marco de la supervivencia requiere incorporar el mecanismo de censura de forma nativa, lo que ha generado adaptaciones específicas de los principales algoritmos, de las cuales el Random Survival Forest cuenta con un gran reconocimiento en la literatura biomédica (P. Wang et al., 2019).

2.3.2 Random Survival Forest

El Random Survival Forest (RSF) fue propuesto por Ishwaran et al. en 2008 como extensión del Random Forest (Breiman, 2001) al contexto de la supervivencia. El RSF construye un ensemble de árboles de supervivencia aleatorios utilizando la función de log-rank como criterio de división de nodos, evaluada sobre subconjuntos aleatorios de variables. Sus ventajas sobre el modelo de Cox incluyen: (i) no asume proporcionalidad de riesgos ni linealidad; (ii) maneja interacciones entre variables; (iii) es robusto frente a datos ausentes; y (iv) proporciona medidas nativas de importancia de variables (VIMP y minimal depth). Jin et al. en 2025 reportaron como el RSF superó significativamente a la regresión de Cox en el índice de concordancia (C-index: 0.803 vs. 0.736) para datos de cáncer de mama.

2.3.3 Gradient Boosting para supervivencia

El *gradient boosting* es una técnica de *ensemble learning* que construye modelos predictivos mediante la combinación secuencial de modelos simples, donde cada iteración busca corregir los errores de las anteriores. En el contexto del análisis de supervivencia, este enfoque puede adaptarse para optimizar funciones de pérdida específicas del problema, como la asociada al modelo de riesgos proporcionales de Cox o métricas de concordancia (Chen et al., 2013). Este enfoque combina la capacidad del *boosting* para manejar conjuntos de datos de alta dimensionalidad con la relativa interpretabilidad del marco de Cox. Aunque su rendimiento puede ser comparable o superior al de métodos basados en árboles como *Random Survival Forest* en determinados escenarios, su adopción en estudios de genómica oncológica ha sido más limitada debido al enorme costo computacional (P. Wang et al., 2019).

2.4 Modelos de aprendizaje profundo para análisis de supervivencia

2.4.1 DeepSurv

El modelo DeepSurv, propuesto por Katzman et al. en 2018 es actualmente el modelo de aprendizaje profundo más citado y adoptado en el campo del análisis de supervivencia oncológica. DeepSurv implementa una red neuronal profunda feedforward que optimiza la función de pérdida de log-verosimilitud parcial de Cox, extendiendo el modelo de Cox al régimen no lineal. La capa de salida es una neurona única sin función de activación que genera la puntuación de riesgo (log hazard ratio) para cada paciente. En el artículo

original, Katzman et al. demostraron mejoras en C-index respecto al Cox estándar y RSF sobre cuatro conjuntos de datos clínicos y genómicos. Particularmente relevante para este TFM es su evaluación sobre datos de cáncer de mama del conjunto de datos METABRIC donde DeepSurv alcanzó un C-index de 0.654 frente a 0.631 del modelo de Cox y frente a 0.619 del modelo RSF. Huang et al. (2020) compararon DeepSurv, RSF y Cox LASSO sobre 12 tipos de cáncer del TCGA, concluyendo que DeepSurv obtiene mejores métricas en la mayoría de ocasiones.

2.4.2 SurvivalNet y arquitecturas alternativas

SurvivalNet, propuesto por Yousefi et al. en 2017, es otro modelo de red neuronal para supervivencia que incorpora regularización mediante dropout, normalización por lotes (batch normalization) y optimización bayesiana de hiperparámetros. Su evaluación sobre cuatro conjuntos de datos de TCGA (glioblastoma, cáncer de mama, cáncer de riñón y cáncer de hígado) demostró mejoras sobre el modelo de Cox en todos los casos.

Más recientemente, la integración de múltiples modalidades de datos genómicos mediante arquitecturas de aprendizaje profundo constituye una de las líneas de investigación más activas en el campo. Tong et al. (2020) propusieron el framework DCAP (Deep Cancer Prognosis), basado en un encoder por modalidad (expresión génica, miRNA, metilación, CNV) seguido de una capa de fusión de características de nivel profundo. Evaluado sobre datos simulados de MNIST y datos multi-ómicos de TCGA-BRCA, DCAP superó a los modelos de una sola modalidad en C-index respecto al uso de expresión génica aislada, con la contribución de cada modalidad variando por tipo de cáncer.

2.4.3 Pipeline metodológico integrado

La figura 3 presenta el diagrama del pipeline metodológico completo que articula las etapas de adquisición de datos, preprocesamiento, modelado y evaluación, incluyendo los mecanismos de validación cruzada interna y externa que se implementarán en este TFM.




Figura 3. Pipeline metodológico del análisis de supervivencia genómico propuesto en el TFM. El flujo muestra las etapas desde la adquisición de datos de TCGA y METABRIC hasta la evaluación mediante métricas estándar, con los mecanismos de validación cruzada interna (k-fold) y validación externa cruzada entre conjuntos de datos.

2.5 Datos genómicos en la predicción del pronóstico oncológico

2.5.1 El proyecto TCGA y su impacto en la investigación

El proyecto The Cancer Genome Atlas (TCGA), lanzado en 2006 por el *National Cancer Institute (NCI)* y el *National Human Genome Research Institute (NHGRI)*, ha supuesto un avance clave en la investigación oncológica traslacional. Este consorcio ha generado perfiles moleculares completos (incluyendo expresión génica mediante RNA-seq, mutaciones somáticas, variaciones en el número de copias, metilación del ADN y datos proteómicos) para más de 11.000 tumores primarios correspondientes a 33 tipos de cáncer, integrados con información clínica y de seguimiento (The Cancer Genome Atlas Research Network et al., 2013). La estandarización de los pipelines de procesamiento a través del GDC Data Portal (Jensen et al., 2017) ha facilitado la comparabilidad entre estudios, permitiendo análisis transversales entre distintos tipos de cáncer con datos procesados bajo protocolos homogéneos. Por ello, TCGA se ha convertido en la fuente de datos predominante en numerosos estudios de modelos de supervivencia basados en genómica desde aproximadamente 2012.

No obstante, TCGA presenta algunas limitaciones relevantes, como una sobrerrepresentación de pacientes de ascendencia europea (aproximadamente entre el 70 % y el 80 % según el tipo de cáncer), lo que puede limitar la capacidad de generalización de los modelos desarrollados a poblaciones más diversas.

2.5.2 El conjunto de datos METABRIC

El conjunto de datos METABRIC (Molecular Taxonomy of Breast Cancer International Consortium), descrito originalmente por Curtis et al. (2012) y ampliado por Pereira et al. (2016) y Rueda et al. (2019), constituye uno de los recursos más robustos y citados en investigación oncológica de cáncer de mama. Este conjunto de datos incluye perfiles de expresión génica por microarrays, variaciones en número de copias y datos clínicos detallados de aproximadamente 1.980 pacientes con cáncer de mama, con información de seguimiento clínico prolongado. Mediante un análisis integrador de expresión génica y alteraciones en número de copias, el estudio identificó diez subgrupos moleculares (IntClust1-10) con perfiles pronósticos diferenciados, algunos de los cuales no se corresponden directamente con la clasificación clínica tradicional ni con los subtipos intrínsecos previamente descritos por Perou et al. (2000).

La amplia disponibilidad de METABRIC a través de plataformas como cBioPortal y el European Genome-phenome Archive ha favorecido su utilización como cohorte independiente de validación en estudios genómicos, especialmente para evaluar modelos entrenados en datos del proyecto The Cancer Genome Atlas. No obstante, existen diferencias técnicas importantes entre ambos recursos (principalmente el uso de microarrays en METABRIC frente a RNA-seq en TCGA) que pueden generar discrepancias sistemáticas en los niveles de expresión génica, por lo que es habitual aplicar técnicas de normalización cruzada o corrección de efectos de lote para garantizar la comparabilidad entre conjuntos de datos (Leek et al., 2012).

2.5.3 Tipos de datos genómicos y su contribución pronóstica

La contribución relativa de cada tipo de dato genómico a la capacidad predictiva de los modelos de supervivencia ha sido analizada en varios estudios comparativos. Tong et al. (2020) encontraron que la expresión génica (miRNA) era consistentemente la modalidad más informativa entre las modalidades individuales, mientras que las CNVs fueron las menos útiles para la supervivencia global. Así mismo, la combinación de metilación del ADN y expresión de miRNA utilizando PCA y el modelo ConcatAE logró superar a modelos de una sola modalidad en términos del C-index.

Por otro lado, las mutaciones somáticas presentan una contribución pronóstica más heterogénea: mientras que en cáncer de pulmón las mutaciones de EGFR y reordenamiento de ALK tienen un valor pronóstico y predictivo bien establecido (Cardarella & Johnson, 2013), en cáncer de mama las mutaciones somáticas aportan información incremental modesta sobre la que ya proporciona la expresión génica (Kandoth et al., 2013). Este fenómeno se explica porque las mutaciones son eventos discretos y su frecuencia de ocurrencia individual es baja en la mayoría de los genes (excepto en genes conductores), mientras que la expresión génica integra el efecto de múltiples alteraciones moleculares aguas abajo.

2.6 Estado del arte en cáncer de mama

2.6.1 Clasificación molecular y pronóstico

La clasificación molecular del cáncer de mama ha sido uno de los avances más importantes en oncología del siglo XXI. La clasificación de Perou et al. (2000) en cuatro subtipos intrínsecos (Luminal A, Luminal B, HER2-enriched y Triple Negativo) mediante perfiles de expresión génica demostró un mayor valor pronóstico que la estadificación TNM convencional. Por ejemplo, el subtipo Luminal subtype C muestra una alta expresión de un conjunto de genes de función desconocida que comparte con los subtipos ER-negativos (basal y ERBB2+), lo que podría explicar su peor pronóstico en comparación con Luminal A (Sørli et al., 2001).

La integración de marcadores genómicos en herramientas de estratificación del riesgo ha transformado la práctica oncológica en cáncer de mama. El test Oncotype DX (Paik et al., 2004) analiza la expresión de 21 genes para cuantificar el riesgo de recurrencia al cancer de mama de forma independiente a los factores clínico-patológicos estándar (edad, tamaño del tumor y el grado histológico). MammaPrint (Brandão et al., 2018) utiliza 70 genes para clasificar pacientes en riesgo alto o bajo de metástasis a distancia. Ambas herramientas han demostrado su utilidad clínica en ensayos aleatorios prospectivos (TAILORx (Sparano et al., 2018) y MINDACT (Cardoso et al., 2016), respectivamente), validando el principio de que los datos genómicos mejoran la precisión pronóstica respecto a los factores clínico-patológicos convencionales.

2.6.2 Modelos de supervivencia basados en TCGA-BRCA y/o METABRIC

En el ámbito del aprendizaje automático, numerosos estudios han aplicado modelos de supervivencia sobre TCGA-BRCA y/o METABRIC. La revisión sistemática de Li et al. (2021)

sobre 31 estudios para predecir la tasa de supervivencia a 5 años constató que: (i) Los métodos más utilizados fueron los árboles de decisión (61.3%), las redes neuronales artificiales (58.1%) y las máquinas de soporte vectorial (51.6%); (ii) el rendimiento de los modelos de ML fue comparable con los modelos de regresión logística o de Cox tradicionales; y (iii) únicamente uno de los 31 estudios realizó validación externa. Mihaylov, Nisheva, y Vassilev (2019) evaluaron múltiples modelos de aprendizaje automático para el pronóstico de supervivencia de dos cohortes ($n = 498$ y $n = 2000$). Utilizando validación cruzada 5-fold, su mejor algoritmo, la regresión de vectores de soporte Lineal (SVR-Lineal), obtuvo un coeficiente de determinación de 0,983. La evaluación de los distintos algoritmos demostró que los modelos lineales superaron a los no lineales, ilustrando cómo una adecuada estructuración jerárquica y normalización de las variables clínicas logra equilibrar los datos y mejorar significativamente la precisión del pronóstico de supervivencia.

En el contexto específico de DeepSurv, Katzman et al. (2018) modelaron directamente las complejas interacciones no lineales entre las características basales de los pacientes y el riesgo de mortalidad. La arquitectura DeepSurv obtuvo un índice de concordancia superior al de los enfoques clásicos de aprendizaje automático, incluyendo el modelo tradicional de riesgos proporcionales de Cox (Cox PH) y los bosques aleatorios de supervivencia (RSF). Además de demostrar una mejora medible en la precisión predictiva a través del C-index, el estudio ilustró que esta red neuronal profunda funciona eficazmente como un sistema de recomendación de tratamientos personalizados, superando las limitaciones de los métodos estadísticos convencionales al lidiar con la alta dimensionalidad y la profunda heterogeneidad intrínseca del cáncer de mama.

2.6.3 Tabla resumen de estudios en cáncer de mama

La tabla 5 sintetiza algunos de los estudios más relevantes en el ámbito del análisis de supervivencia aplicado a datos oncológicos, destacando los conjuntos de datos utilizados, el tipo de datos de entrada, los modelos empleados y su rendimiento en términos de *C-index*. Asimismo, se recogen los principales hallazgos de cada trabajo, permitiendo identificar tendencias metodológicas y enfoques predominantes en la literatura.

Tabla 5. Síntesis de estudios clave en análisis de supervivencia de cáncer de mama con datos genómicos.

Estudio	Conjunto/s de datos	Datos de entrada	Mejor modelo	C-index	Hallazgo principal
Chen et al. (2013)	METABRIC	Variables clínicas y perfiles de expresión genética/proteica	GBMCI	0,74	GBMCI supera consistentemente a modelos como Cox PH y RSF.
Katzman et al. (2018)	WHAS, SUPPORT, METABRIC, Rotterdam & GBSG, datos simulados	Variables clínicas y perfiles de expresión genética/proteica	DeepSurv	0,86	DeepSurv modela con gran precisión interacciones complejas y no lineales, capaz de incrementar el tiempo de supervivencia de los pacientes.
Mihaylov et al. (2019)	TCGA	Registros clínicos	SVR-Linear	NR	Los modelos lineales sencillos en estudios

					de baja dimensionalidad consiguen una alta predicción.
Tong et al. (2020)	TCGA-BRCA	Datos multi-ómicos	ConcatAE	0,64	Los modelos multimodales presentan mejores predicciones que los unimodales
Jin et al. (2025)	Cohorte interna	Variables clínico-patológicas	RSF	0,80 - 0,91	El modelo RSF supera a la regresión de Cox para identificar riesgos de supervivencia

*NR: No reportado explícitamente como C-index en los fragmentos del estudio, aunque se presentan otros valores estadísticos de supervivencia.

2.7 Estado del arte en cáncer de pulmón no microcítico (NSCLC)

2.7.1 Heterogeneidad molecular y relevancia pronóstica

La evolución del tratamiento del cáncer de pulmón ha transitado de una clasificación basada exclusivamente en la histología hacia una caracterización molecular profunda. El proyecto cBioPortal DataHub (Collisson et al., 2014) marcó un hito al definir el paisaje genómico del adenocarcinoma de pulmón (LUAD), identificando variantes impulsoras (*driver mutations*) en el 75% de los tumores analizados. Esta disección molecular ha permitido establecer que mutaciones en genes como *EGFR*, *ALK* y *KRAS* no solo definen subtipos biológicos, sino que son determinantes para el pronóstico y la selección de terapias dirigidas (Pao & Girard, 2011).

A diferencia del cáncer de mama, donde las firmas multigénicas de riesgo (como Oncotype DX) están altamente estandarizadas, en el cáncer de pulmón la estratificación del riesgo y la supervivencia se han vinculado recientemente a la carga mutacional del tumor y a la expresión de biomarcadores (Hellmann et al., 2018).

2.7.2 Modelos de supervivencia basados en datos genómicos y machine learning

La integración de datos multi-ómicos ha permitido el desarrollo de modelos de supervivencia que superan la capacidad predictiva del sistema de estadificación TNM convencional.

Intentando replicar el éxito de herramientas como MammaPrint, se validaron una firma de 14 genes mediante RT-PCR en una cohorte de más de 1,500 pacientes (Kratz et al., 2012). Este modelo demostró una capacidad superior para estratificar a los pacientes en grupos de riesgo alto, intermedio y bajo, independientemente de los factores clínico-patológicos. Por su parte, Wang et al. (2021) desarrollaron una firma basada en perfiles de mRNA relacionados con la ferroptosis, vinculando procesos metabólicos con la supervivencia a largo plazo.

El uso de redes neuronales para modelar la supervivencia ha ganado relevancia con la arquitectura DeepSurv. Katzman et al. (2018) aplicaron este enfoque de riesgos proporcionales de Cox basado en aprendizaje profundo para capturar interacciones no lineales entre variables clínicas y moleculares, demostrando que supera a los métodos estadísticos tradicionales al lidiar con la alta heterogeneidad del cáncer de pulmón. En una línea similar, She et al. (2020) utilizaron la arquitectura DeepSurv, obteniendo un C-index de 0.742, validando que el aprendizaje profundo es capaz de extraer patrones pronósticos complejos que escapan a los modelos lineales.

La literatura reciente subraya que la clave para mejorar la precisión reside en la integración de datos. Lai et al. (2020) desarrollaron una red neuronal profunda combinando fuentes de datos genómicas y clínicas, concluyendo que la combinación de datos clínicos con perfiles transcriptómicos mejora la precisión predictiva respecto a los modelos que solo utilizan variables clínicas. Finalmente, Lee et al. (2020) proponen arquitecturas multimodales que fusionan metilación, mutación y RNA-seq, alcanzando índices de concordancia de hasta 0.762, lo que representa el estado del arte actual en la predicción de la supervivencia para esta patología.

2.7.3 Tabla resumen de estudios en cáncer de pulmón

La tabla 6 recoge una selección de estudios recientes centrados en la predicción de supervivencia en cáncer de pulmón, destacando los conjuntos de datos utilizados, los tipos de datos de entrada y los modelos más eficaces en cada caso. Asimismo, se incluyen métricas de rendimiento como el C-index o el AUC, junto con los principales hallazgos derivados de cada trabajo.

Tabla 6. Síntesis de estudios clave en análisis de supervivencia de cáncer de pulmón no microcítico con datos genómicos.

Estudio	Conjunto/s de datos	Datos de entrada	Mejor modelo	C-index	Hallazgo principal
Lai et al. (2020)	Cohorte de 614 pacientes (microarrays) y E-MTAB-923	15 biomarcadores genéticos y datos clínicos (edad, sexo, estadio)	Red Neuronal Profunda	0.82 (AUC)**	La integración de datos moleculares y clínicos mediante Deep Learning mejora drásticamente la predicción de supervivencia a 5 años.
Lee et al. (2020)	TCGA-LUAD, GSE81089, GSE63805, GSE63384	Multi-ómica: mRNA, miRNA, metilación del ADN y CNV	Autoencoder basado en Deep Learning + Random Forest	0.65	El uso de autoencoders para integrar cuatro tipos de datos ómicos permite una estratificación de riesgo más robusta que los métodos de una sola ómica.
She et al. (2020)	SEER y base de datos de China (Shanghai)	127 características (clínicas, demográficas y del tumor)	DeepSurv	0.74	DeepSurv supera al sistema de estadificación TNM tradicional en la predicción de

	Pulmonary Hospital)				supervivencia específica y en recomendaciones de tratamiento personalizadas.
Wang et al. (2021)	TCGA y GSE72094	Firma de 13 genes relacionados con la ferroptosis e infiltración inmune	Modelo de regresión LASSO Cox y Nomograma	0.69 (AUC)**	Se validó una firma genética de ferroptosis que predice de forma independiente la supervivencia y se relaciona con el microambiente inmune.
Didier et al. (2024)	Meta-análisis de 12 estudios (211,068 pacientes)	Variables clínicas y radiómicas	Modelos de Machine Learning	0.78	Los modelos de Machine Learning muestran una capacidad discriminativa superior (C-index 0.78) frente a la regresión logística tradicional (0.70).

*NR: No reportado explícitamente como C-index en los fragmentos del estudio, aunque se presentan otros valores estadísticos de supervivencia.

**En algunos estudios de Deep Learning se reporta el AUC como métrica principal de discriminación, la cual es análoga al C-index en modelos de clasificación de supervivencia.

2.8 Validación cruzada entre conjuntos de datos y generalización de modelos

2.8.1 Importancia y estado actual

La evaluación de la generalización de los modelos predictivos mediante validación externa en cohortes independientes es un requisito metodológico fundamental que, a pesar de su importancia, se cumple de forma muy inconsistente en la literatura de aprendizaje automático oncológico. La revisión de Li et al. (2021) que el campo sufre de una falta crítica de estandarización, validación externa y transparencia en el manejo de datos. Dhiman et al. (2021) confirmaron este hallazgo en una revisión más amplia, identificando una pobre y urgente necesidad de mejora de los modelos de predicción clínicos.

Este déficit tiene implicaciones directas en la aplicabilidad clínica de los modelos desarrollados. Ramspek et al. (2021) argumentan que la validación interna (ya sea mediante partición train/test o validación cruzada) solo permite estimar la varianza del rendimiento, pero no puede detectar los sesgos derivados de la selección de la cohorte, las diferencias en los protocolos de recogida de datos o la heterogeneidad poblacional. La validación externa, definida como la evaluación del modelo sobre una cohorte recopilada de forma independiente y en un contexto diferente al de entrenamiento, es el único mecanismo que permite establecer con rigor la generalización del modelo.

2.8.2 Estudios de validación TCGA – METABRIC

En el ámbito específico de cáncer de mama con datos genómicos, la combinación TCGA-BRCA + METABRIC es la más frecuentemente utilizada para validación cruzada. La diferencia fundamental entre ambos conjuntos de datos (RNA-seq vs. microarrays) plantea la necesidad de normalización cruzada o corrección de efectos de lote antes de la comparación directa de expresión génica a nivel de valores brutos. Sin embargo, los métodos de puntuación de actividad de vías (pathway activity scores) o de genes de firma (signature scores), al operar en un espacio de características derivadas, son más robustos frente a estas diferencias de plataforma (Hänzelmann et al., 2013).

Para mitigar el impacto de las diferencias entre conjuntos de datos, se han desarrollado diversas estrategias metodológicas. Jensen et al. (2017) describieron el proceso de armonización del GDC, que reanaliza todos los datos del TCGA con pipelines estandarizados para minimizar las diferencias debidas al procesamiento computacional. Para las diferencias de plataforma tecnológica (microarrays vs. RNA-seq), un modelo de efectos mixtos bayesiano para corrección de batch effects o la transformación a rangos percentiles de expresión son los más utilizados en la literatura (Johnson et al., 2007; Yousefi et al., 2017). En el contexto de este TFM, la estrategia de armonización adoptada se documentará y justificará en el Capítulo 3 (Datos).

2.9 Métricas de evaluación en modelos de supervivencia

2.9.1 El índice de concordancia (C-index)

El índice de concordancia (Harrell's C-index) (HARRELL Jr. et al., 1996) es la métrica más utilizada en la literatura para evaluar el poder discriminativo de modelos de supervivencia. Mide la probabilidad de que, dado un par de pacientes del que uno ha experimentado el evento, el modelo asigne un riesgo mayor al paciente que experimenta el evento primero. Su interpretación es análoga al área bajo la curva ROC para datos binarios: valores de 0,5 indican rendimiento aleatorio, y valores de 1,0 indican discriminación perfecta. En la práctica, los modelos publicados en cáncer de mama y pulmón reportan C-index en el rango 0,60-0,80, con los valores más elevados correspondiendo a modelos que integran múltiples modalidades de datos genómicos.

Una limitación del C-index es que es una medida de rango que no evalúa la calibración del modelo, es decir, si las probabilidades de supervivencia predichas se corresponden cuantitativamente con las observadas. Dos modelos con el mismo C-index pueden tener calibraciones radicalmente distintas, lo que tiene implicaciones directas en su aplicación clínica. Por esta razón, el uso del C-index debe complementarse con otras métricas (Kar et al., 2023).

2.9.2 El Brier Score integrado

El Brier Score (Graf et al., 1999) para supervivencia mide el error cuadrático medio entre la probabilidad de supervivencia predicha por el modelo y el resultado binario observado (vivo/muerto) a un tiempo t dado. El Brier Score integrado (IBS) promedia el Brier Score sobre todos los tiempos del horizonte de seguimiento, proporcionando una medida conjunta de calibración y discriminación. Un IBS de 0 indica predicción perfecta, un IBS de 0,25 corresponde al score de un modelo que asigna $P(\text{supervivencia}) = 0,5$ a todos los

sujetos independientemente de sus características (modelo nulo). En la práctica, los modelos bien calibrados en datos oncológicos alcanzan IBS en el rango 0,15-0,22.

2.9.3 El test de log-rank y la estratificación de riesgo

El test de log-rank (Baum & Henderson, 2004) es el test estadístico estándar para comparar curvas de supervivencia entre grupos. En el contexto de los modelos predictivos, se utiliza habitualmente para evaluar si la estratificación de los pacientes en grupos de riesgo (alto vs. bajo, basada en el score de riesgo del modelo) resulta en diferencias de supervivencia estadísticamente significativas. Esta evaluación complementa las métricas continuas (C-index, IBS) con una evaluación categórica de la utilidad clínica del modelo para estratificar pacientes.

2.10 Síntesis comparativa y brechas de conocimiento

2.10.1 Comparativa de C-index por familia metodológica

La figura 3 resume los rangos de C-index reportados en la literatura para cada familia metodológica, evidenciando la progresión desde los modelos clásicos hasta los enfoques de aprendizaje profundo. Los valores corresponden a estudios sobre datos de cáncer de mama y pulmón de TCGA y/o METABRIC, tal como se cita a lo largo del capítulo.




Figura 4. Rangos de C-index reportados en la literatura por familia metodológica para modelos de supervivencia aplicados a cáncer de mama y pulmón sobre TCGA y/o METABRIC. Las barras muestran el valor medio y las líneas de error el rango mínimo-máximo reportado en los estudios revisados. La línea roja discontinua marca el nivel de rendimiento aleatorio (C-index =0.50).

2.10.2 Cuadro resumen global de metodologías y líneas de trabajo

La tabla 7 presenta una síntesis estructurada de las principales técnicas y líneas metodológicas empleadas en el análisis de supervivencia, organizadas según su eje temático, nivel de interpretabilidad y limitaciones. Además, se incluyen referencias clave que sustentan cada enfoque, así como su relevancia específica dentro del contexto del presente TFM.

Tabla 7. Cuadro resumen de las técnicas y líneas de investigación analizadas en el Capítulo 2: características metodológicas, referencias fundacionales y relevancia para el TFM.

Técnica / Línea	Eje temático	Referencia clave	Interpretabilidad	Limitación principal	Relevancia TFM
Métodos clásicos de supervivencia					
Kaplan-Meier	Estadística clásica	Kaplan y Meier (1958)	Muy alta	No multivariable; no predictivo	Baseline descriptivo
Cox proporcional	Estadística clásica	Cox (1972)	Alta	No aplica cuando $p \gg n$; asume proporcionalidad	Modelo referencia
Cox LASSO	Estadística clásica	Tibshirani (1997)	Media-Alta	Asume linealidad; una sola variable por grupo colineal	Modelo referencia penalizado
Machine Learning para supervivencia					
Random Survival Forest	ML (ensemble)	Ishwaran et al. (2008)	Media (VIMP)	Coste comp. alto; n mínimo recomendado ~300	Modelo ML principal
Gradient Boosting	ML (ensemble)	Chen et al. (2013)	Media	Menor adopción en genómica; sensible a outliers	Referencia comparativa
Survival SVM	ML (kernel)	Van Belle et al. (2011)	Baja	Escasa escalabilidad con $p > 10.000$ variables	Ref. conceptual
Deep Learning para supervivencia					
DeepSurv	Deep Learning	Katzman et al. (2018)	Baja (SHAP)	Requiere n grande; sobreajuste con $n < 500$; opaco	Modelo DL principal
SurvivalNet	Deep Learning	Yousefi et al. (2017)	Baja	Menor difusión; HP optimization costosa	Ref. alternativa DL
Transformers multimodales	Deep Learning	Tong et al. (2020)	Baja	Requiere $n \gg 1.000$; complejidad extrema	Línea futura
Fuentes de datos y					

herramientas de validación					
TCGA (GDC)	Repositorio genómico	The Cancer Genome Atlas Research Network et al. (2013)	—	Sesgo de ancestría europea; heterogéneo por tipo	Conjunto de datos primario
METABRIC	Repositorio genómico	Curtis et al. (2012)	—	Solo mama; microarrays	Conjunto de datos val. externa
Validación externa	Metodología	Ramspek et al. (2021)	—	Solo el 3% de estudios realizan; deficitaria	Diferenciador TFM
Métricas de evaluación					
C-index	Métrica discriminativa	HARRELL Jr. et al. (1996)	Alta	No evalúa calibración; sensible a censura informativa	Métrica principal
Brier Score integrado	Calibración + discrim.	Graf et al. (1999)	Media	Menos intuitivo; depende del horizonte temporal	Métrica secundaria
Log-rank test	Comparación grupos	Baum y Henderson (2004)	Alta	Solo evalúa diferencia categórica entre grupos	Estratificación de riesgo

2.10.3 Brechas de conocimiento identificadas

La revisión permite identificar las siguientes brechas que justifican el diseño del presente TFM:

- Déficit sistemático de validación externa: la mayoría de los estudios no la realizan, imposibilitando establecer la generalización real de los modelos publicados.
- Escasez de comparaciones multi-modelo sistemáticas: los estudios suelen comparar un modelo nuevo únicamente con el Cox estándar, sin evaluaciones exhaustivas entre familias metodológicas en condiciones experimentales idénticas.
- Heterogeneidad en pipelines de preprocesamiento: la falta de estandarización dificulta la comparación entre estudios y puede ser fuente importante de variabilidad en los resultados.

- Análisis insuficiente de transferibilidad TCGA-BRCA $\leftrightarrow$ METABRIC con modelos complejos: la validación cruzada de RSF y DeepSurv entre ambas cohortes es escasa y no sistematizada.
- Limitada aplicación de criterios de interpretabilidad en DeepSurv: los estudios que aplican DeepSurv raramente complementan los resultados con análisis SHAP, dificultando la traducción biológica de los hallazgos.

El presente TFM aborda explícitamente las tres primeras brechas al proponer validación cruzada entre TCGA y METABRIC (brecha 1), comparación de cuatro familias metodológicas en igualdad de condiciones (brecha 2) y documentación exhaustiva y reproducible del pipeline de preprocesamiento (brecha 3). Las brechas cuarta y quinta orientan el análisis de interpretabilidad del OE5 y la discusión del Capítulo 6.

CAPÍTULO 3. MATERIAL Y MÉTODOS

3.1. Diseño general del estudio

El presente Trabajo de Fin de Máster se plantea como un estudio observacional retrospectivo basado en el análisis secundario de datos clínicos y moleculares procedentes de cohortes oncológicas públicas. El objetivo metodológico principal consiste en preparar, transformar y estructurar diferentes conjuntos de datos de pacientes con cáncer de mama y cáncer de pulmón no microcítico para su posterior utilización en modelos de análisis de supervivencia.

El diseño del estudio parte de la premisa de que los datos de supervivencia presentan dos componentes fundamentales: el tiempo hasta la ocurrencia del evento de interés y el indicador de censura. En este trabajo, el evento principal analizado es la muerte del paciente, mientras que los pacientes vivos o sin registro del evento al final del seguimiento se consideran observaciones censuradas.

La estrategia metodológica se organiza en varias fases sucesivas: selección de cohortes, adquisición de datos, análisis exploratorio, depuración de registros, definición de variables de supervivencia, selección de covariables, imputación de valores ausentes, tratamiento de valores extremos, codificación de variables categóricas, escalado de variables numéricas, división en conjuntos de entrenamiento y prueba, y generación de objetos compatibles con los modelos de supervivencia.

3.2. Fuentes de datos y cohortes analizadas

Para el desarrollo del trabajo se utilizaron tres cohortes clínicas procedentes de cBioPortal DataHub. Dos de ellas corresponden a cáncer de mama (METABRIC y TCGA-BRCA) y una a cáncer de pulmón no microcítico (MSK_NSCLC). La selección de estas cohortes responde a tres criterios principales: disponibilidad pública, presencia de variables clínicas de supervivencia y existencia de información clínica o molecular potencialmente útil para el modelado pronóstico.

Tabla 8. Características principales de las cohortes utilizadas en el estudio.

Característica	METABRIC	TCGA-BRCA	MSK-NSCLC 2022
Tipo de cáncer	Mama	Mama	Pulmón no microcítico metastásico
Fuente / Disponibilidad	cBioPortal / Acceso público	cBioPortal / Acceso público	cBioPortal / Acceso público
Archivo utilizado	brca_metabric_clinical_data.tsv	brca_tcga_gdc_clinical_data.tsv	nsclc_ctdx_msk_2022_clinical_data.tsv
N muestras	2.509	1.102	2.621
N variables	39	44	35
Tecnología genómica	Microarrays	RNA-seq, GDC	ctDNA, NGS dirigido
Uso en el TFM	Entrenamiento y validación externa	Entrenamiento y validación externa	Análisis de cáncer de pulmón

3.2.1. Cohorte METABRIC

La primera cohorte utilizada fue METABRIC, correspondiente al estudio *Molecular Taxonomy of Breast Cancer International Consortium*. Esta cohorte contiene información clínica y molecular de pacientes con cáncer de mama, incluyendo variables demográficas, características tumorales, subtipos moleculares, tratamientos recibidos y variables de supervivencia global.

El archivo utilizado fue 'brca_metabric_clinical_data.tsv'. El conjunto de datos inicial contenía 2.509 registros y 39 columnas. Tras el proceso de limpieza, eliminación de variables no informativas o redundantes, creación de la variable objetivo y exclusión de registros sin información suficiente de supervivencia, se obtuvo un conjunto final de 1.981 pacientes.

METABRIC se utilizó como una de las cohortes principales de cáncer de mama, especialmente por su tamaño muestral, la presencia de variables clínicas detalladas y su amplia utilización en estudios previos de supervivencia oncológica.

3.2.2. Cohorte TCGA-BRCA

La segunda cohorte utilizada fue TCGA-BRCA, correspondiente al subconjunto de cáncer de mama invasivo del proyecto *The Cancer Genome Atlas*. El archivo empleado fue 'brca_tcga_gdc_clinical_data.tsv'.

El conjunto inicial contenía 1.102 registros y 44 columnas. Se identificaron registros duplicados asociados a múltiples muestras por paciente, por lo que se conservó una única observación por paciente. Tras esta deduplicación, el conjunto quedó reducido a 1.095 registros. Posteriormente, al eliminar un registro sin información completa para construir la variable de supervivencia, se obtuvo un conjunto final de 1.094 pacientes.

TCGA-BRCA se utilizó como cohorte independiente de cáncer de mama, permitiendo comparar el comportamiento de los modelos frente a METABRIC y explorar la robustez metodológica entre cohortes con distinta procedencia.

3.2.3. Cohorte MSK-NSCLC

La tercera cohorte utilizada fue MSK-NSCLC 2022, correspondiente a pacientes con cáncer de pulmón no microcítico metastásico. El archivo empleado fue 'nslc_ctdx_msk_2022_clinical_data.tsv'.

El conjunto inicial contenía 2.621 registros y 37 columnas. En primer lugar, se filtraron los registros correspondientes específicamente a cáncer de pulmón no microcítico, eliminándose 82 observaciones. Posteriormente, se aplicó un proceso de deduplicación para conservar una única muestra por paciente, priorizando las muestras tumorales frente a cfDNA y, dentro de ellas, siguiendo una jerarquía según el tipo de muestra. Este proceso eliminó 1.412 registros duplicados, dando lugar a un conjunto final de 1.127 pacientes.

Esta cohorte se incorporó como caso de estudio de cáncer de pulmón, permitiendo evaluar la aplicabilidad del pipeline metodológico en un tipo tumoral distinto al cáncer de mama.

3.3. Estrategia de adquisición de datos

Se optó por descargar datos en formato ‘.tsv’ desde cBioPortal DataHub, priorizando la reproducibilidad y una integración fluida con el ecosistema de Python. Al prescindir de herramientas como la API de GDC o TCGAbiolinks, se minimizaron las dependencias externas y los conflictos de compatibilidad, logrando una estructura homogénea para la carga y el preprocesamiento de las tres cohortes. Finalmente, los archivos se almacenaron localmente y se procesaron mediante notebooks independientes, asegurando la trazabilidad de cada análisis

3.4. Entorno computacional y herramientas utilizadas

El procesamiento y análisis de los datos se realizó en Python mediante notebooks de Jupyter (disponibles en [GitHub](#)). Se desarrolló un cuaderno específico para cada cohorte, con el objetivo de mantener la trazabilidad de las decisiones metodológicas y facilitar la reproducibilidad.

Las librerías principales utilizadas se agruparon según su función dentro del flujo de trabajo. Para la manipulación de datos se emplearon pandas y numpy; para el preprocesamiento, scikit-learn; para los modelos de supervivencia, lifelines, scikit-survival y pycox; para el modelado profundo, PyTorch; y para la visualización, matplotlib y seaborn.

También se utilizaron funciones auxiliares propias, diseñadas para automatizar tareas repetitivas de exploración, descripción de variables y revisión de valores ausentes.

3.5. Análisis exploratorio de datos

3.5.1. Revisión de valores nulos o ausentes

Antes del modelado se evaluó la presencia de valores ausentes. En METABRIC aparecieron nulos en variables clínicas, moleculares y de supervivencia; en TCGA-BRCA, principalmente en algunas variables clínicas; y en MSK-NSCLC, sobre todo en variables moleculares y relacionadas con la muestra. Esta revisión permitió definir los criterios de imputación y exclusión aplicados posteriormente.

3.5.2. Exploración de variables categóricas

Las variables categóricas fueron analizadas mediante gráficos de frecuencia. Este análisis permitió identificar categorías poco frecuentes, categorías desconocidas, variables con una única categoría dominante y variables que podían generar un número elevado de columnas tras la codificación *one-hot*.

A. Variables categóricas en la cohorte de METABRIC

I. Identificadores y metadatos de varianza cero

Se identificaron y descartaron diversos elementos que no aportan valor estadístico al modelo. En primer lugar, se eliminaron los identificadores únicos destinados al

seguimiento individual de los sujetos y sus muestras (Patient ID, Sample ID). Asimismo, se detectaron atributos que mantienen un valor constante en toda la cohorte; esta ausencia de variabilidad (varianza cero) los inhabilita como covariables predictivas (Study ID, Cancer Type, Sample Type, Sex).




Figura 5. Variables identificadoras y metadatos del estudio en METABRIC.

II. Perfil clínico-demográfico y anatómico

El grupo de estudio se compone fundamentalmente de pacientes en etapa postmenopáusica (Inferred Menopausal State = Post). Respecto a la ubicación del tumor (Primary Tumor Laterality), existe una proporción equilibrada entre ambos lados del cuerpo, lo que descarta la presencia de un sesgo anatómico significativo en la muestra. Finalmente, los niveles de densidad celular (Cellularity) detectados se sitúan mayoritariamente en rangos que sugieren una tendencia hacia la progresión acelerada y una marcada capacidad de invasión.




Figura 6. Variables sobre el perfil clínico-demográfico y anatómico en METABRIC.

III. Caracterización histológica y patológica

Dado que las diversas clasificaciones histopatológicas (Cancer Type Detailed, Tumor Other Histologic Subtype, Oncotree Code) disponibles proporcionan información altamente similar, se observó que la gran mayoría de la muestra corresponde a una tipología específica de carcinoma, con una presencia significativamente menor de otras variantes. Por ello, con el fin de optimizar el análisis y eliminar la redundancia estadística, se optó por conservar únicamente la categorización que ofrece el nivel de descripción más detallado sobre la naturaleza de la patología, Cancer Type Detailed.




Figura 7. Variables sobre la caracterización histológica y patológica en METABRIC.

IV. Biomarcadores moleculares y subtipos

El perfil biológico predominante se caracteriza por la positividad en los receptores hormonales (ER status measured by IHC, ER Status, PR Status) y la ausencia del factor de crecimiento epidérmico (HER2 Status). En coherencia con esta tendencia, los subtipos moleculares (Pam50 + Clauding-lox subtype, 3-Gene classifier subtype) vinculados a la sensibilidad hormonal son los más frecuentes en la clasificación estándar. Complementariamente, otro esquema de agrupación molecular presenta una distribución más atomizada, segmentando la muestra en una mayor diversidad de nichos específicos (Integrative Cluster).




Figura 8. Variables sobre biomarcadores Moleculares y Subtipos en METABRIC.

V. Intervenciones terapéuticas

Se observa una marcada asimetría en la administración del tratamiento sistémico más agresivo (Chemotherapy), que fue aplicado solo en una minoría de los casos, mientras que el recurso a las terapias endocrinas (Hormone Therapy) y de radiación (Radio Therapy) resulta significativamente más frecuente, en plena consonancia con el protocolo estándar para este perfil molecular. Asimismo, en cuanto al abordaje quirúrgico (Type of Breast Surgery), la tendencia se inclina ligeramente hacia la extirpación completa frente a las técnicas orientadas a la conservación del tejido.




Figura 9. Variables sobre intervenciones terapéuticas en METABRIC.

VI. Variables de supervivencia

El seguimiento clínico (Overall Survival Status) presenta una tasa de eventos significativa para el estudio, registrándose el fallecimiento de una parte considerable de la cohorte durante el periodo de observación. En contraste, la mayoría de los sujetos no mostró signos de recurrencia de la patología (Relapse Free Status). Debido a esta relación, se decidió prescindir del indicador de la condición vital (Patient's Vital Status) para evitar redundancias informativas con el evento principal analizado.




Figura 10. Variables del estado de supervivencia en METABRIC.

B. Variables categóricas en la cohorte de TCGA_BRCA

I. Identificadores y metadatos del estudio

Los diversos indicadores destinados a la identificación individual de los sujetos y sus muestras biológicas (Patient ID, Other Patient ID, Sample ID, Other Sample ID, Biopsy Site, Patient Primary Tumor Site, Cancer Type, Cancer Type Detailed, Oncotree Code) fueron descartados como covariables predictivas. Del mismo modo, se prescindió de aquellos atributos con funciones meramente administrativas o que presentan una categoría predominante, lo que limita su utilidad estadística (American Joint Committee on Cancer Publication Version Type, Is FFPE, Project identifier, Project Name, Project State).




Figura 11. Variables identificadoras y metadatos del estudio en TCGA-BRCA.

II. Perfil clínico-demográfico y anatómico

El conjunto analizado está compuesto casi en su totalidad por mujeres (Sex = Female), lo cual es coherente con la patología estudiada. En términos sociodemográficos (Ethnicity Category, Race Category), predomina un grupo étnico y raza principal sobre otras minorías representadas, con una clara mayoría de pacientes blancos de origen no hispano. Respecto a la procedencia de las muestras (Sample Type), casi todas corresponden a la lesión original, con una presencia mínima de casos con diseminación a distancia. Asimismo, el perfil clínico general revela que la mayor parte de la muestra no cuenta con antecedentes de otras enfermedades malignas (Prior Malignancy) ni ha recibido terapias previas (Prior Treatment) antes de su inclusión en el estudio.




Figura 12 Variables sobre el Perfil clínico-demográfico y anatómico en TCGA-BRCA

III. Caracterización histológica y estadificación AJCC

La muestra se caracteriza por la clara predominancia del carcinoma ductal invasivo, seguida por la variante lobulillar y otras tipologías minoritarias, una tendencia que se mantiene constante en las diversas clasificaciones diagnósticas utilizadas (Disease Type, Primary Diagnosis, Morfology). En cuanto a la extensión de la enfermedad, sobresalen las etapas de afectación localizada o regional, con especial énfasis en los estadios de avance intermedio (AJCC Pathologic N-Stage, AJCC Pathologic Stage). Del mismo modo, la gran mayoría de los casos se encuentran en una fase sin evidencia de propagación a órganos distantes (ICD-10 Classification, AJCC Pathologic M-Stage), frente a una proporción mínima con afectación sistémica. Debido a su relevancia para anticipar la evolución clínica, estas dimensiones se conservaron como pilares fundamentales para el modelado.

Caracterización Histológica y Estadificación AJCC

Cohorte: TCGA-BRCA



Figura 13. Variables sobre la Caracterización histológica y estadificación AJCC en TCGA-BRCA.

IV. Variables de estado de supervivencia

Los indicadores de evolución clínica revelan una baja frecuencia de sucesos (Overall Survival Status), ya que la vasta mayoría de los sujetos permanecen con vida al cierre del periodo de observación. Esta elevada proporción de casos sin el evento de interés supone un desafío significativo para que el modelo identifique patrones asociados a la mortalidad. De igual modo, la situación de los pacientes refleja mayoritariamente la ausencia de recaídas (Disease Free Status) o progresión de la patología (Patient's Vital Status). Finalmente, solo la frecuencia de sucesos se utilizó en el análisis como variable descriptiva del evento, mientras que el resto se desecharon.




Figura 14. Variables del estado de supervivencia en TCGA-BRCA

C. Variables categóricas en la cohorte de MSK_NSCLC

I. Identificadores y metadatos del estudio

Los códigos de identificación individual (Patient ID, Sample ID, Patient Display Name), y de origen del estudio (Study ID) se omitieron del análisis predictivo por su naturaleza no informativa. Asimismo, se detectó una marcada asimetría en cuanto al centro hospitalario de origen (Site), con una localización aportando la gran mayoría de los casos frente a una presencia minoritaria de la otra. Estos elementos se descartaron para el modelado final al carecer de utilidad estadística.




Figura 15. Variables identificadoras y metadatos del estudio en MSK-NSCLC.

II. Perfil clínico-demográfico y anatómico

El grupo de estudio presenta una paridad notable en su composición por género (Sex), sin que predomine de forma marcada un grupo sobre otro. Desde el punto de vista sociodemográfico (Ethnicity Category, Race Category), prevalece una categoría racial específica sobre el resto de las minorías representadas, con una gran mayoría de pacientes blancos de origen no hispano. Asimismo, existe un equilibrio entre los sujetos con y sin antecedentes de consumo de tabaco (Smoking Status). Debido a su influencia potencial en el comportamiento biológico del tumor y en la evolución clínica de los pacientes, estos atributos se consideraron fundamentales para el desarrollo del modelo.

Perfil Clínico-Demográfico y Anatómico

Cohorte: MSK_NSCLC




Figura 16. Variables sobre el perfil clínico-demográfico y anatómico en MSK-NSCLC.

III. Clasificación patológica y diagnóstica

La población analizada se concentra casi en su totalidad en una forma específica de patología pulmonar, dentro de la cual destaca de manera abrumadora el adenocarcinoma de pulmón (LUAD) frente a otras variantes mucho menos frecuentes. Este patrón de distribución se ve respaldado por los diversos criterios de clasificación diagnóstica empleados (Cancer Type, Cancer Type Detailed, Histology, Oncotree Code), que confirman la hegemonía de esta tipología sobre el resto de las manifestaciones de la enfermedad. En consecuencia, el modelado y las conclusiones obtenidas estarán condicionados fundamentalmente por las características biológicas y el comportamiento de este grupo mayoritario.

Cohorte: MSK_NSCLO



Respecto a la naturaleza de las muestras (Sample Type), se observa una clara mayoría de origen secundario en comparación con las obtenidas del foco inicial o de recurrencias locales. Esta tendencia se ve reforzada por la presencia de una proporción significativa de sujetos con afectación fuera de la región pulmonar (Extrapulmonary), destacando la propagación a estructuras linfáticas (Metastatic Site = Lymph Node), hígado y cerebro. En conjunto, estos hallazgos ratifican que el estudio se centra primordialmente en pacientes con la enfermedad en estadios avanzados o con diseminación a distancia.

Cohorte: MSK_NSCLC



Figura 18. Variables sobre la localización y naturaleza de la muestra en MSK_NSLC.

V. Metodología y calidad genómica

El conjunto de datos exhibe cierta diversidad técnica en cuanto a las plataformas de secuenciación empleadas (Gene Panel), siendo predominante la herramienta de inteligencia artificial, ctDx pulmonar. La efectividad de estos procedimientos fue sumamente alta (Successful ctDx Lung), lográndose resultados válidos en la gran mayoría de los casos. Respecto a la estabilidad genómica, la muestra se caracteriza por una presencia abrumadora de tumores estables (MSI Type) frente a una incidencia mínima de inestabilidad. Asimismo, se observa una variabilidad considerable en la concentración de células tumorales (Tumor Purity), un factor determinante que puede condicionar la sensibilidad para detectar alteraciones moleculares. Todas estas dimensiones fueron supervisadas para asegurar la integridad, calidad y comparabilidad de la información genética procesada.




Figura 19. Variables sobre la Metodología y calidad genómica en MSK-NSCLC.

VI. Variable objetivo y tratamiento

La evolución clínica de los sujetos (Overall Survival Status) muestra una proporción sumamente equilibrada entre los casos de fallecimiento y supervivencia, lo que garantiza una densidad de eventos óptima para la robustez del modelado. Asimismo, la presencia de intervenciones terapéuticas anteriores (Prior Treatment) en una fracción de la muestra se identificó como un factor crítico para el pronóstico, dado que haber recibido tratamiento previo suele reflejar diferencias en el avance de la enfermedad o en la posible resistencia a nuevas terapias.




Figura 20. Variable objetivo y tratamiento en MSK-NSCLC.

3.5.3. Exploración de variables numéricas

Las variables numéricas fueron analizadas mediante visualizaciones de frecuencia. Este análisis permitió identificar variables con distribuciones asimétricas, presencia de valores extremos y escalas muy diferentes, justificando posteriormente la aplicación de winsorización y estandarización.

A. Variables numéricas en la cohorte de METABRIC

I. Demografía.

La distribución de la edad en que se identifica la patología (Age at Diagnosis) sigue una curva de campana que refleja un espectro muy amplio de etapas vitales. Asimismo, la clasificación según el periodo de captación (Cohorte) de los registros muestra diversos núcleos de concentración en las fases iniciales del estudio. Este factor fue descartado del análisis final debido a su escasa trascendencia clínica y a la elevada fragmentación de sus categorías.




Figura 21. Variables sobre la demografía y contexto de la cohorte en METABRIC.

II. Parámetros clínico-patológicos

Las dimensiones de la patología (Tumor Size, Tumor Stage) muestran un predominio de tamaños moderados, aunque con una presencia de casos aislados de gran volumen que sugieren estadios muy avanzados de la enfermedad. Respecto a la afectación de los tejidos linfáticos (Lymph nodes examined positive), la gran mayoría de los sujetos no presenta propagación, si bien se identifican perfiles excepcionales de alta agresividad con una carga ganglionar muy elevada. Finalmente, el indicador pronóstico integral (Nottingham prognostic index) y el grado histológico de una neoplasia (Neoplasm Histologic Grade) reflejan una diversidad de células cancerosas en la muestra, situando el nivel de riesgo predominantemente en rangos intermedios y elevados.




Figura 22. Variables sobre parámetros clínico-patológicos en METABRIC.

III. Métricas de agresividad molecular.

Los indicadores de carga mutacional (Mutation Count) y densidad de alteraciones (TMB (nonsynonymous)) presentan una concentración en niveles mínimos, lo que ratifica la notable estabilidad genómica de esta patología en su fase inicial en comparación con los perfiles observados en otros tejidos malignos.




Figura 23. Métricas de agresividad molecular en METABRIC.

IV. Variables temporales de supervivencia.

Los tiempos de observación (Overall Survival (Months)), tanto para la supervivencia general como para el periodo libre de recurrencia (Relapse Free Status (Months)), presentan una amplitud extraordinaria que se extiende a lo largo de varias décadas. Este seguimiento clínico prolongado permite capturar la evolución de la enfermedad a muy largo plazo, lo que representa una de las ventajas competitivas más notables de la cohorte para el análisis de la trayectoria vital de los pacientes.




Figura 24. Métricas de Supervivencia en METABRIC.

B. Variables numéricas en la cohorte de TCGA_BRCA

I. Variables de estructura muestral

El análisis de la frecuencia de registros por individuo (Number of Samples Per Patient) reveló que, si bien la mayor parte de la cohorte cuenta con un único aporte biológico, existen excepciones con múltiples entradas asociadas. Esta revisión fue fundamental para identificar redundancias y justificar la consolidación de los datos en una sola observación por sujeto previo al modelado. Asimismo, se examinó el indicador del

tipo de muestra (`Sample type id`) como parte del control de integridad estructural, aunque se descartó como factor clínico relevante para el estudio.




Figura 25. Variables de Estructura Muestral en TCGA-BRCA.

II. Demografía y diagnóstico

La edad al diagnóstico (`Diagnosis Age`) presenta una distribución compatible con una cohorte adulta de cáncer de mama, mientras que las variables temporales asociadas a diagnóstico, contacto y fallecimiento (`Last Communication Contact from Initial Pathologic Diagnosis Date`, `Birth from Initial Pathologic Diagnosis Date`, `Death from Initial Pathologic Diagnosis Date`, `Year of Diagnosis`) se revisaron con precaución por su relación directa con el seguimiento clínico. Finalmente, excepto la edad del diagnóstico, el resto de variables fueron excluidas del estudio.

Demografía y Diagnóstico

Cohorte: TCGA-BRCA




Figura 26. Variables sobre la Demografía y diagnóstico en TCGA-BRCA.

III. Métricas de agresividad molecular

Diversas métricas de la carga molecular permiten caracterizar la inestabilidad de los tumores (Fraction Genome Altered, Mutation Count, TMB (nonsynonymous)), mostrando una distribución donde predominan niveles bajos junto a casos aislados con una mayor alteración genómica.




Figura 27. Métricas de agresividad molecular en TCGA-BRCA.

IV. Métricas de supervivencia

La supervivencia global en meses (Overall Survival (Months)) presenta una distribución asimétrica, con un número elevado de pacientes censurados y una cola de seguimientos prolongados. La supervivencia libre de enfermedad (Disease Free (Months)) muestra un patrón similar.




Figura 28. Métricas de supervivencia en TCGA-BRCA.

C. Variables numéricas en la cohorte de MSK_NSCLC

I. Granularidad del seguimiento

Se detectó que una fracción relevante de la cohorte posee múltiples entradas registradas (Number of Samples Per Patient), con casos que van desde una presencia duplicada hasta volúmenes de información mucho mayores por individuo. Este hallazgo motivó la aplicación de un protocolo de filtrado para asegurar que cada sujeto estuviera representado por una única observación. Así, se evitó la sobrerrepresentación de ciertos perfiles individuales y posibles distorsiones en el análisis.




Figura 29. Variables de Granularidad del seguimiento en MSK-NSCLC.

II. Carga genómica y estabilidad molecular

Los indicadores de carga mutacional (Mutation Count, TMB nonsynonymous, MSI Score) presentan una distribución muy asimétrica, con la mayoría de los casos en niveles bajos y pocos sujetos con mayor inestabilidad molecular. De forma similar, la fracción del genoma alterado (Fraction Genome Altered) se mantiene en rangos reducidos, confirmando la estabilidad biológica predominante de la cohorte. Dada su relevancia para anticipar agresividad tumoral, respuesta terapéutica y desenlace clínico, estos parámetros se conservaron como variables clave del modelo predictivo.




Figura 30. Variables sobre la carga genómica y estabilidad molecular en MSK-NSCLC.

III. Carga tumoral física y estadificación

La medición del volumen metabólico del cáncer (Metabolic Tumor Volume) muestra una marcada asimetría, donde predominan las cargas bajas, pero conviven con valores

excepcionalmente elevados, lo que evidencia una gran heterogeneidad en la masa tumoral física de los pacientes. Por otra parte, el indicador del estadio clínico (Stage at Draw) presenta una categoría abrumadoramente mayoritaria, lo que limita su capacidad para diferenciar perfiles en el modelo. Este comportamiento justificó la aplicación de protocolos específicos para tratar valores atípicos en las variables cuantitativas del conjunto de datos.




Figura 31. Variables sobre la carga tumoral física y estadificación en MSK-NSCLC.

IV. Métricas de supervivencia y tiempo

El perfil de los sujetos se sitúa predominantemente en una etapa vital avanzada (Patient Current Age). Respecto al tiempo transcurrido hasta el evento clínico (Overall Survival (Months)), los datos muestran una mayor densidad en los periodos iniciales de observación, aunque existe un grupo menor con una permanencia excepcionalmente larga.




Figura 32. Métricas de supervivencia y tiempo en MSK-NSCLC

3.5.4. Análisis de correlaciones

El análisis de correlaciones permitió identificar asociaciones esperadas entre variables y depurar los conjuntos de datos. A partir de este proceso, se descartaron elementos

duplicados o redundantes y se refinó la selección de los factores que formarían parte del modelo final.

A. Correlaciones entre variables numéricas METABRIC

El análisis de correlaciones de las variables numéricas en la cohorte de METABRIC, revela vínculos críticos entre las dimensiones cuantitativas del estudio. Existe una equivalencia casi absoluta entre los dos indicadores de carga molecular (Mutation Count <-> TMB (nonsynonymous) = 1.00) lo que confirma su redundancia y justifica la selección de un único representante para el análisis. Asimismo, se detectó una estrecha dependencia entre los tiempos de supervivencia general y el periodo libre de recurrencia (Overall Status (Months) <-> Relapse Free Status (Months) = 0.90), lo que obliga a prescindir de este último para evitar la filtración de información en el modelado. Finalmente, el indicador de riesgo integral (Nottingham prognostic index) muestra una asociación coherente con el grado de diferenciación del tejido (Neoplasm Histologic Grade = 0.70), la extensión de la enfermedad (Tumor Stage = 0.55) y las dimensiones de la lesión (Tumor Size = 0.29), ratificando su utilidad para resumir la agresividad clínica del tumor.




Figura 33. Mapa de calor de correlaciones de las variables numéricas en METABRIC.

B. Correlaciones entre variables numéricas TCGA-BRCA

El análisis de correlaciones de las variables numéricas en la cohorte TCGA-BRCA revela dependencias críticas entre distintos indicadores temporales del seguimiento clínico y del desenlace final. Existe una equivalencia prácticamente absoluta entre el tiempo hasta fallecimiento y la supervivencia global (Death from Initial Pathologic Diagnosis Date <-> Overall Survival (Months) = 1.00), así como una asociación muy alta entre el último contacto clínico y la supervivencia global (Last Communication Contact from Initial Pathologic Diagnosis Date <-> Overall Survival (Months) = 0.92). Del mismo modo, se detecta una redundancia total entre las métricas de carga mutacional (Mutation Count <-> TMB (nonsynonymous) = 1.00), lo que justifica conservar solo una de ellas para evitar duplicidad de información genómica. Asimismo, existe una relación inversa exacta entre el tiempo desde el nacimiento hasta el diagnóstico y la edad al diagnóstico (Birth from Initial Pathologic Diagnosis Date <-> Diagnosis Age = -1.00), confirmando que ambas variables representan la misma dimensión temporal desde perspectivas opuestas.




Figura 34. Mapa de calor de correlaciones de las variables numéricas en TCGA_BRCA.

C. Correlaciones entre variables numéricas MSK_NSCLC

El análisis de correlaciones de las variables numéricas en la cohorte MSK_NSCLC revela que la mayoría de los factores cuantitativos mantienen relaciones débiles o moderadas entre sí. No obstante, destaca una vinculación muy elevada entre los indicadores de carga mutacional (Mutation Count <-> TMB (nonsynonymous) = 0.92), lo que confirma que ambos parámetros capturan un fenómeno biológico similar y aportan información parcialmente redundante. Asimismo, se detecta una asociación relevante entre el grado de alteración genómica estructural y la pureza tumoral de la muestra (Fraction Genome Altered <-> Tumor Purity_numeric = 0.59), sugiriendo una relación entre la inestabilidad genómica y la concentración de células malignas. También se observa una correspondencia casi absoluta entre la edad actual del paciente y la edad reportada en la secuenciación (Patient Current Age <-> Age at Which Sequencing was Reported (Years)_numeric = 0.99), lo que evidencia redundancia temporal entre ambas variables.

Mapa de Calor de Correlaciones




Figura 35. Mapa de calor de correlaciones de las variables numéricas en MSK-NSCLC.

3.6. Criterios de inclusión, exclusión y deduplicación

La preparación de los datos exigió aplicar criterios de inclusión y exclusión específicos para cada cohorte. El objetivo fue obtener un conjunto analítico final con una única observación por paciente, variables de supervivencia válidas y ausencia de columnas redundantes, identificadoras o con riesgo de fuga de información.

3.6.1. Criterios generales de inclusión

Se incluyeron los registros que cumplían las siguientes condiciones:

1. Pertenecer al tipo tumoral de interés.
2. Disponer de información suficiente para construir la variable de tiempo de supervivencia.
3. Disponer de información suficiente para construir el indicador de evento.
4. Representar una única observación por paciente.
5. Contener al menos un subconjunto de covariables clínicas y/o moleculares utilizables para el modelado.

3.6.2. Criterios generales de exclusión

Se excluyeron:

1. Registros duplicados correspondientes a múltiples muestras del mismo paciente.
2. Registros sin información de supervivencia global.
3. Variables identificadoras, como identificadores de paciente o muestra.
4. Variables administrativas o metadatos sin utilidad predictiva directa.
5. Variables redundantes respecto a otras más completas o interpretables.
6. Variables derivadas directamente del evento o del tiempo de supervivencia.
7. Variables con riesgo de fuga de información.
8. Variables sin señal univariante clara en Kaplan-Meiers/log-rank (solo en Cox-LASSO).

3.6.3. Deduplicación de registros

En TCGA-BRCA se detectaron 7 registros duplicados asociados a múltiples muestras por paciente. Se conservó una única muestra por paciente, obteniendo 1.095 registros antes de la eliminación de valores nulos en la variable objetivo.

En MSK-NSCLC se detectó una mayor multiplicidad muestra-paciente. Tras filtrar los registros de cáncer de pulmón no microcítico, se aplicó una jerarquía de prioridad para seleccionar una única muestra por paciente. Se priorizaron las muestras tumorales frente a cfDNA y, dentro del tipo de muestra, se priorizaron las muestras primarias frente a metástasis, recurrencias locales o muestras desconocidas. Este proceso eliminó 1.412 registros, quedando 1.127 pacientes únicos.

En METABRIC no fue necesario aplicar una deduplicación específica por muestra-paciente en el mismo sentido, pero sí se eliminaron registros sin información suficiente para construir las variables de supervivencia.

3.7. Definición de las variables de supervivencia

Todos los modelos de supervivencia utilizados requieren una definición común de la variable objetivo. Para ello, se construyeron dos variables:

- `duration`: tiempo de seguimiento o supervivencia global, expresado en meses.
- `event`: indicador binario del evento de interés.

En las tres cohortes, `duration` se obtuvo a partir de `Overall Survival (Months)` y `event` se derivó de `Overall Survival Status`. Esta última variable se codificó como 1 cuando la muerte fue observada durante el seguimiento y como 0 cuando la observación fue censurada.

Los registros con valores ausentes en `duration` fueron eliminados, ya que no pueden emplearse en modelos de supervivencia. Además, los tiempos iguales a cero se sustituyeron por un valor mínimo positivo de 0,001 meses, evitando problemas numéricos en modelos que no aceptan tiempos nulos sin alterar de forma relevante su significado clínico. Esta corrección afectó a 1 registro en METABRIC y a 20 registros en TCGA-BRCA. En MSK-NSCLC no se detectaron tiempos de supervivencia iguales a cero.

3.8. Selección de covariables para el modelado

Una vez definidas las variables objetivo, se seleccionaron las covariables candidatas para el modelado. Este proceso se realizó de forma independiente en cada cohorte, dado que las variables disponibles no eran idénticas. La selección de covariables siguió los criterios definidos en el punto 3.6.2.

3.8.1. Covariables seleccionadas en METABRIC

En METABRIC se conservaron 21 covariables candidatas:

- Age at Diagnosis
- Type of Breast Surgery
- Cancer Type Detailed
- Cellularity
- Chemotherapy
- Pam50 + Claudin-low subtype
- ER Status
- Neoplasm Histologic Grade
- HER2 Status
- Hormone Therapy
- Inferred Menopausal State
- Integrative Cluster
- Primary Tumor Laterality
- Lymph nodes examined positive
- Nottingham prognostic index
- PR Status
- Radio Therapy
- 3-Gene classifier subtype
- TMB (nonsynonymous)
- Tumor Size
- Tumor Stage

Estas variables permiten representar aspectos centrales del cáncer de mama, como edad, estadio, tamaño tumoral, grado histológico, afectación ganglionar, subtipo molecular, receptores hormonales y tratamientos recibidos.

3.8.2. Covariables seleccionadas en TCGA-BRCA

En TCGA-BRCA se conservaron 15 covariables candidatas:

- Diagnosis Age
- Disease Type
- Ethnicity Category
- Fraction Genome Altered
- ICD-10 Classification
- Morphology
- AJCC Pathologic M-Stage
- AJCC Pathologic N-Stage
- AJCC Pathologic Stage
- AJCC Pathologic T-Stage
- Prior Malignancy
- Prior Treatment
- Race Category
- Sex
- TMB (nonsynonymous)

Estas variables permiten incorporar información demográfica, estadio patológico, antecedentes clínicos y variables moleculares generales como la fracción del genoma alterado y la carga mutacional tumoral.

3.8.3. Covariables seleccionadas en MSK-NSCLC

En MSK-NSCLC se conservaron 19 covariables candidatas:

- Patient Current Age
- Cancer Type Detailed
- Ethnicity Category
- Extrapulmonary
- Fraction Genome Altered
- Gene Panel
- Metabolic Tumor Volume
- Metastatic Site
- MSI Score
- MSI Type
- Primary Tumor Site
- Prior Treatment
- Race Category
- Sample Class
- Sample Type
- Sex
- Smoking Status
- TMB (nonsynonymous)

- Tumor Purity_numeric

Estas variables recogen información clínica, molecular, demográfica y relacionada con la muestra. En el caso del cáncer de pulmón no microcítico, se incluyeron además variables relevantes como el tabaquismo, la localización metastásica, el tipo de muestra, la carga mutacional, la puntuación MSI, el volumen tumoral metabólico y la pureza tumoral.

3.9. Preprocesamiento de datos

El preprocesamiento tuvo como objetivo transformar los datos clínicos originales en matrices numéricas limpias, completas y compatibles con los modelos de supervivencia. Todas las transformaciones que podían aprender parámetros del conjunto de datos, se ajustaron exclusivamente sobre el conjunto de entrenamiento y se aplicaron posteriormente al conjunto de prueba. Esta estrategia evitó la fuga de información desde el conjunto de test hacia el proceso de entrenamiento.

3.9.1. División en conjuntos de entrenamiento y prueba

Cada cohorte fue dividida en un conjunto de entrenamiento y un conjunto de prueba mediante una partición 80/20. La división se realizó de forma estratificada según el indicador de evento, con el objetivo de preservar la proporción de eventos y censura en ambos subconjuntos. Se utilizó una semilla aleatoria fija para garantizar la reproducibilidad de los experimentos.

Tabla 9. División train/test por cohorte

Cohorte	Registros train	Tasa de eventos en train	Registros test	Tasa de eventos en test
METABRIC	1.584	57,77 %	397	57,68 %
TCGA-BRCA	875	13,83 %	219	13,70 %
MSK-NSCLC	901	54,83 %	226	54,87 %

3.9.2. Imputación de valores ausentes

Los valores ausentes se trataron de forma diferenciada según el tipo de variable. En las variables numéricas se aplicó imputación mediante la mediana calculada en el conjunto de entrenamiento. Esta estrategia es robusta frente a valores extremos y adecuada para variables clínicas con distribuciones asimétricas.

En las variables categóricas se utilizó una categoría explícita denominada 'Unknown'. Esta decisión evita la eliminación de registros con información parcial y permite que la ausencia de información sea tratada como una categoría adicional por los modelos.

Tras la imputación, tanto el conjunto de entrenamiento como el conjunto de prueba quedaron sin valores nulos en las covariables.

3.9.3. Tratamiento de valores extremos

Algunas variables numéricas presentaban valores extremos potencialmente influyentes sobre modelos sensibles a la escala y la distribución de las variables, como Cox y DeepSurv. Para reducir su impacto, se aplicó *winsorización* empírica entre los percentiles 1 y 99. Los umbrales fueron calculados exclusivamente sobre el conjunto de entrenamiento y

aplicados posteriormente al conjunto de prueba. Las variables tratadas por cohorte fueron:

- En METABRIC se aplicó sobre: edad (`Age at Diagnosis`), ganglios positivos (`Lymph nodes examined positive`), carga mutacional (TMB (`nonsynonymous`)), tamaño tumoral (`Tumor Size`) y estadio tumoral (`Tumor Stage`).
- En TCGA-BRCA se aplicó sobre: edad (`Diagnosis Age`), fracción alterada del genoma (`Fraction Genome Altered`), y carga tumoral (TMB (`nonsynonymous`)).
- En MSK-NSCLC se aplicó sobre las mismas que en TCGA_BRCA.

3.9.4. Codificación de variables categóricas

Los modelos utilizados requieren entradas numéricas, por lo que las variables categóricas fueron transformadas mediante codificación *one-hot*. Se utilizó `OneHotEncoder` con eliminación de la primera categoría (`drop='first'`) para reducir la multicolinealidad perfecta entre variables indicadoras. Además, se utilizó `handle_unknown='ignore'` para tolerar la aparición de categorías no observadas durante el entrenamiento en el conjunto de prueba. Tras la codificación, los conjuntos finales quedaron con 56 covariables en METABRIC, 88 covariables en TCGA-BRCA y 88 covariables en MSK-NSCLC.

3.9.5. Escalado de variables numéricas

Las variables numéricas originales fueron estandarizadas mediante `StandardScaler`, restando la media y dividiendo por la desviación estándar calculadas en el conjunto de entrenamiento. Aunque los modelos basados en árboles, como `Random Survival Forest`, no requieren escalado, se mantuvo un pipeline homogéneo para facilitar la comparación entre modelos y asegurar la compatibilidad con modelos sensibles a la escala, como `Cox` y `DeepSurv`.

3.9.6. Conversión a formatos compatibles con modelos de supervivencia

Finalmente, las variables objetivo se transformaron en formatos compatibles con las librerías de supervivencia utilizadas.

- Para `scikit-survival`, se generaron arrays estructurados con dos campos: `event` y `duration`.
- Para `lifelines`, se generaron `dataframes` que integran covariables, `duration` y `event`.
- Para `DeepSurv` y `pycox`, se prepararon matrices `numpy` de covariables y arrays separados de `duration` y `event`.

3.10. Modelos de supervivencia implementados

En este trabajo se implementaron cuatro enfoques de análisis de supervivencia con distinto nivel de complejidad: Kaplan-Meier, Cox penalizado, `Random Survival Forest` y `DeepSurv`.

3.10.1. Estimador de Kaplan-Meier

El estimador de Kaplan-Meier se utilizó como método no paramétrico para estimar la función de supervivencia de cada cohorte. Su función principal en este trabajo fue visualizar la probabilidad de supervivencia a lo largo del tiempo e identificar diferencias entre grupos clínicos o moleculares.

La función de supervivencia estimada se expresa como:

$$\hat{s}(T) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i}\right)$$

donde d_i representa el número de eventos en el tiempo t_i y n_i el número de pacientes en riesgo justo antes de ese tiempo.

Para permitir el análisis univariante, las variables continuas se discretizan en categorías clínicas o cuartiles. Esta transformación es exclusiva para Kaplan-Meier; los modelos Cox, RSF y DeepSurv utilizaron las variables originales para preservar su valor predictivo.

3.10.2. Modelo de Cox penalizado

El modelo de Cox penalizado se utilizó como modelo semiparamétrico clásico de referencia. Su función principal fue estimar la relación entre las covariables y el riesgo de muerte, incorporando una penalización sobre los coeficientes para mejorar la estabilidad del ajuste y reducir el sobreajuste.

El modelo se basa en la siguiente función de riesgo:

$$h(t|X) = h_o(t) \exp(\beta X)$$

donde $h_o(t)$ es la función basal de riesgo, X representa el vector de covariables del paciente y β el vector de coeficientes estimados por el modelo.

3.10.3. Random Survival Forest

Random Survival Forest se implementó como modelo de aprendizaje automático para supervivencia. Su función principal fue capturar relaciones no lineales e interacciones entre variables sin asumir proporcionalidad de riesgos.

El modelo construye múltiples árboles de supervivencia a partir de subconjuntos aleatorios de pacientes y covariables. En cada árbol, las divisiones se realizan buscando separar grupos con distinta supervivencia, habitualmente mediante criterios basados en el test log-rank. Para cada paciente, la predicción final se obtiene agregando el riesgo acumulado estimado por todos los árboles del bosque:

$$\hat{H}_{RSF}(t|x) = \frac{1}{B} \sum_{b=1}^B \hat{H}_{l_b(x)}(t)$$

donde (B) es el número total de árboles, $\hat{H}_{b(x)}(t)$ representa el riesgo acumulado estimado en el nodo terminal alcanzado por el paciente (x) en el árbol (b), y $\hat{H}_{RSF}(t|x)$ es el riesgo acumulado promedio estimado por el bosque.

3.10.4. DeepSurv

DeepSurv se utilizó como modelo de aprendizaje profundo para supervivencia. Su función principal fue aprender relaciones no lineales entre las covariables y el riesgo de evento mediante una red neuronal *feedforward*, manteniendo la formulación de riesgos proporcionales del modelo de Cox. En este modelo, el término lineal de Cox se sustituye por una función no lineal aprendida por la red neuronal:

$$h(t|x) = h_0(t) \exp(\phi(x; \theta))$$

donde $h_0(t)$ es la función basal de riesgo, X representa las covariables del paciente, $\phi(x; \theta)$ es el log-riesgo estimado por la red y θ son los parámetros entrenables del modelo.

El entrenamiento se realizó mediante la optimización de la log-verosimilitud parcial negativa de Cox, lo que permite ajustar el modelo considerando tanto los eventos observados como los pacientes en riesgo en cada instante de seguimiento.

Arquitectura del modelo DeepSurv




Figura 36. Arquitectura del modelo DeepSurv, ejemplo en TCGA-BRCA.

3.11. Estrategia de validación

La evaluación inicial de los modelos se realizó mediante una partición entrenamiento/prueba en cada cohorte, manteniendo la proporción de eventos mediante estratificación. En los modelos con ajuste de hiperparámetros (RSF y DeepSurv) se aplicó una validación cruzada estratificada de 5 particiones sobre el conjunto de entrenamiento, con el objetivo de seleccionar la mejor configuración y estimar la variabilidad del rendimiento.

Se realizó una validación externa cruzada entre METABRIC y TCGA-BRCA usando covariables comunes armonizadas: edad al diagnóstico, carga mutacional tumoral, grupo histológico, estadio tumoral y afectación ganglionar. Las variables exclusivas de una sola cohorte fueron excluidas para asegurar una comparación equivalente. El mejor modelo de cada cohorte de origen, y se evaluó en la cohorte externa. El preprocesamiento se ajustó solo con los datos de entrenamiento y luego se aplicó al conjunto externo, evitando fuga de información.

3.12. Métricas de evaluación

El rendimiento de los modelos se evaluó mediante métricas estándar de análisis de supervivencia:

- C-index: métrica principal de discriminación. Evalúa si el modelo asigna mayor riesgo a los pacientes que experimentan antes el evento. Valores cercanos a 0,5 indican rendimiento aleatorio y valores próximos a 1 indican mayor capacidad predictiva.
- Brier Score integrado: métrica complementaria que evalúa el error de predicción de supervivencia a lo largo del tiempo. Valores más bajos indican mejor calibración y menor error.
- Log-rank test: prueba estadística utilizada para comparar curvas de supervivencia entre grupos de riesgo.
- Curvas Kaplan-Meier estratificadas: visualización utilizada para comprobar si los modelos separan adecuadamente pacientes de alto y bajo riesgo.

3.13. Estrategia de interpretabilidad

La interpretabilidad se adaptó al modelo principal de cada cohorte, en términos de C-index e Integrated Brier Score sobre el conjunto de prueba. En Cox penalizado, se analizaron los coeficientes y *hazard ratios* para identificar variables asociadas con mayor o menor riesgo. Para los modelos Random Survival Forest se empleó *permutation importance*, estimando la degradación media del C-index al permutar cada variable en el conjunto de prueba. Para el modelo DeepSurv se aplicó análisis SHAP, evaluando la contribución de las variables más relevantes al score de riesgo estimado por la red neuronal.

CAPÍTULO 4. RESULTADOS

4.1. Introducción al capítulo

Este capítulo se detallan los hallazgos obtenidos tras ejecutar el pipeline de análisis en las cohortes METABRIC, TCGA-BRCA y MSK-NSCLC.

4.2. Características finales de las cohortes analizadas

Tras el proceso de limpieza, deduplicación, exclusión de registros sin información suficiente de supervivencia y transformación de variables, las tres cohortes quedaron preparadas para el modelado de supervivencia. La tabla 11 resume el tamaño final de cada cohorte, el número de eventos observados, las observaciones censuradas y el rango temporal de seguimiento.

Tabla 10. Distribución final de eventos de supervivencia por cohorte.

Cohorte	Registros finales	Eventos observados	Observaciones censuradas	Tasa de eventos	Tiempo mínimo tras corrección	Tiempo máximo
METABRIC	1.981	1.144	837	57,75 %	0,0010 meses	355,20 meses
TCGA-BRCA	1.094	151	943	13,80 %	0,0010 meses	282,69 meses
MSK-NSCLC	1.127	618	509	54,84 %	0,0329 meses	181,27 meses

La cohorte METABRIC presentó el mayor número de eventos observados en términos absolutos, con 1.144 fallecimientos registrados. MSK-NSCLC mostró una tasa de eventos similar a METABRIC, con 618 eventos observados y una proporción de eventos del 54,84 %. En cambio, TCGA-BRCA presentó una tasa de eventos considerablemente menor, con 151 eventos observados sobre 1.094 pacientes, lo que supone una tasa del 13,80 %.

4.3. Supervivencia global mediante Kaplan-Meier

Las curvas de supervivencia global estimadas mediante Kaplan-Meier para cada cohorte se muestran en la Figura 37. La mediana de supervivencia fue de 156,3 meses en METABRIC y 130,1 meses en TCGA-BRCA, ambas superiores a los 10 años. En contraste, MSK-NSCLC presentó una mediana mucho menor, de 27,6 meses, coherente con el carácter metastásico de la cohorte y con el peor pronóstico del cáncer de pulmón no microcítico avanzado.




Figura 37. Curvas de Kaplan-Meier globales no estratificadas de las tres cohortes: METABRIC (Arriba), TCGA-BRCA (En medio) y MSK-NSCLC (Abajo).

4.4. Comparación univariante de supervivencia mediante test log-rank

Los resultados del log-rank en la tabla 12, muestran que las variables clínicas clásicas, especialmente las relacionadas con edad, afectación ganglionar y estadio tumoral,

mantienen una capacidad relevante para separar curvas de supervivencia. Asimismo, en METABRIC aparecen variables moleculares de clasificación tumoral, mientras que en MSK-NSCLC destacan variables asociadas al perfil clínico, a la muestra y a características del proceso diagnóstico o terapéutico.

Tabla 11. Resumen del test log-rank por cohorte. Las variables significativas presentan un p -value < 0.05 .

Cohorte	Variables evaluadas	Variables significativas	Principales variables con diferencias significativas
METABRIC	20	16	Nodal Status, Age Group, NPI Group, Tumor Stage, Integrative Cluster, PAM50
TCGA-BRCA	15	7	AJCC N-Stage, AJCC Stage, AJCC M-Stage, AJCC T-Stage, Age Group
MSK-NSCLC	17	11	Prior Treatment, Cancer Type Detailed, Sample Class, Gene Panel, Sample Type, Smoking Status

4.5. Resultados del modelo Cox-LASSO

La selección de variables realizada por Cox-LASSO mostró diferencias entre cohortes. En METABRIC aparecieron variables clínicas, anatomopatológicas y moleculares relacionadas con subtipos de cáncer de mama. En TCGA-BRCA predominaron las variables de estadificación AJCC y variables moleculares generales. En MSK-NSCLC, las variables seleccionadas recogieron información clínica, molecular y relacionada con la extensión de la enfermedad.

Tabla 123. Variables principales seleccionadas por Cox-LASSO por cohorte. Las variables

Cohorte	Variables con mayor riesgo (HR > 1)	Variables con menor riesgo (HR < 1)
METABRIC	Integrative Cluster_5, Age at Diagnosis, Menopausal State_Pre, Lymph nodes examined positive, Tumor Stage, Tumor Size	HER2+, PAM50 claudin-low, PAM50 LumA, PR Status_Positive
TCGA-BRCA	AJCC N-Stage_NX, AJCC T-Stage_T4b, AJCC N-Stage_N1b, AJCC N-Stage_N2, Diagnosis Age, Fraction Genome Altered	AJCC T-Stage_TX, Stage IA, N-Stage_N0, Morphology_8522/3
MSK-NSCLC	Smoking Status_True, Sex_Male, Metabolic Tumor Volume, Extrapulmonary_True, Fraction Genome Altered	Prior Treatment_True, MSI Score

4.6. Resultados de la búsqueda de hiperparámetros

La configuración óptima resultante de la búsqueda de hiperparámetros varió entre cohortes, lo que refleja las diferencias en tamaño muestral, composición clínica y estructura de las variables disponibles en cada conjunto de datos.

En el caso de Random Survival Forest, las combinaciones seleccionadas muestran variaciones tanto en el número de árboles como en los criterios de división de los nodos. METABRIC requirió un bosque de mayor tamaño, con 500 árboles, mientras que TCGA-BRCA y MSK-NSCLC alcanzaron su mejor configuración con 200 árboles. Asimismo, el parámetro max_features alternó entre $\log_2$ y $\sqrt{\cdot}$, indicando que la proporción óptima de variables consideradas en cada división dependió de las características específicas de cada cohorte.

Tabla 13. Hiperparámetros seleccionados para Random Survival Forest por cohorte.

Cohorte	Nº árboles	max_features	min_samples_split
METABRIC	500	log2	10
TCGA-BRCA	200	sqrt	20
MSK-NSCLC	200	log2	6

Para DeepSurv, también se observaron diferencias en la arquitectura y en los parámetros de entrenamiento. METABRIC y MSK-NSCLC seleccionaron una arquitectura más compacta, formada por dos capas ocultas de 64 neuronas, mientras que TCGA-BRCA requirió una red de mayor capacidad, con capas de 128 y 64 neuronas. El valor de *dropout* osciló entre 0,1 y 0,2, incorporando regularización para reducir el riesgo de sobreajuste. Del mismo modo, la tasa de aprendizaje y el tamaño de lote variaron entre cohortes, lo que evidencia la necesidad de ajustar el proceso de entrenamiento a la complejidad y estabilidad de cada conjunto de datos.

Tabla 14. Arquitectura e hiperparámetros seleccionados para DeepSurv por cohorte.

Cohorte	Arquitectura	Dropout	Learning rate	Batch size
METABRIC	[64, 64]	0,1	0,01	256
TCGA-BRCA	[128, 64]	0,2	0,001	128
MSK-NSCLC	[64, 64]	0,2	0,01	256

4.8. Comparación global del rendimiento de los modelos

Los resultados muestran que el rendimiento de los modelos varió entre cohortes (figura 38). Así mismo, Kaplan-Meiers se representa como referencia marginal por cohorte.

En METABRIC, Random Survival Forest presentó el comportamiento más sólido, combinando la mayor capacidad discriminativa (C-index = 0.706) con el menor error predictivo (IBS = 0.180). DeepSurv también obtuvo un rendimiento competitivo y superó a Cox-LASSO en discriminación, aunque ambos modelos mostraron un IBS muy similar.

En TCGA-BRCA, DeepSurv fue el modelo con mejor equilibrio entre discriminación (C-index = 0.740) y calibración (C-index = 0.104), alcanzando los mejores valores en ambas métricas. Cox-LASSO mostró también un rendimiento elevado y cercano, especialmente en términos de IBS, mientras que Random Survival Forest quedó por debajo en capacidad discriminativa dentro de esta cohorte.

En MSK-NSCLC, Random Survival Forest volvió a destacar como el modelo con mejor rendimiento global (C-index = 0.643; IBS = 0.203). En esta cohorte, DeepSurv obtuvo un IBS ligeramente inferior al de Cox-LASSO (comportamiento opuesto a sus C-index), lo que sugiere una calibración temporal algo más favorable pese a una capacidad discriminativa similar.




Figura 38. Comparación del C-index e IBS en test entre Cox-LASSO, Random Survival Forest y DeepSurv por cohorte.

En conjunto, los resultados indican que no existe un único modelo dominante para todas las cohortes. Random Survival Forest mostró un rendimiento especialmente consistente en METABRIC y MSK-NSCLC, mientras que DeepSurv fue más favorable en TCGA-BRCA. Cox-LASSO mantuvo un comportamiento competitivo, sobre todo en TCGA-BRCA, lo que confirma su utilidad como modelo lineal regularizado de referencia frente a enfoques más flexibles.


Tabla 15. Mejor modelo por cohorte según C-index e IBS en test.


Cohorte	Mejor modelo según C-index	C-index	Mejor modelo según IBS	IBS
METABRIC	Random Survival Forest	0,7060	Random Survival Forest	0,1796
TCGA-BRCA	DeepSurv	0,7398	DeepSurv	0,1040

MSK-NSCLC	Random Survival Forest	0,6433	Random Survival Forest	0,2032
-----------	------------------------	--------	------------------------	--------

4.9. Estratificación de riesgo mediante modelos principales

Las curvas de Kaplan-Meier evidencian en las tres cohortes, como los pacientes clasificados con mayor riesgo presentan una reducción más rápida de la probabilidad de supervivencia, mientras que los grupos de menor riesgo mantienen una evolución más favorable. Además, las diferencias observadas son estadísticamente significativas según el test log-rank, lo que respalda la utilidad pronóstica de las puntuaciones estimadas por los modelos





En METABRIC, el modelo Random Survival Forest muestra una separación muy clara entre los grupos de bajo y alto riesgo. La curva del grupo de alto riesgo desciende de forma mucho más rápida, mientras que el grupo de bajo riesgo mantiene una supervivencia claramente superior durante casi todo el seguimiento. Esta diferencia es altamente significativa en la comparación binaria ($\log\text{-rank } p = 9,99 \times 10^{-19}$). La estratificación por cuartiles refuerza este resultado, ya que las curvas siguen un gradiente ordenado: el cuartil de menor riesgo presenta la mejor supervivencia y el de mayor riesgo la peor ($\log\text{-rank multivariante } p = 6,34 \times 10^{-22}$). Esto indica que el modelo no solo separa dos grupos extremos, sino que también discrimina niveles intermedios de riesgo.

En TCGA-BRCA, el modelo DeepSurv también consigue diferenciar perfiles pronósticos. En la división binaria, el grupo de bajo riesgo mantiene una supervivencia superior al grupo de alto riesgo, con una diferencia estadísticamente significativa ($\log\text{-rank } p = 4,14 \times 10^{-4}$). En la división por cuartiles, el grupo de mayor riesgo muestra la peor evolución, mientras que el grupo de menor riesgo conserva la supervivencia más favorable ($\log\text{-rank multivariante } p = 5,14 \times 10^{-4}$). No obstante, la separación entre algunos cuartiles intermedios es menos marcada que en METABRIC, lo que sugiere una capacidad de estratificación útil, aunque menos nítida.

En MSK-NSCLC, el modelo Random Survival Forest separa de forma significativa a los pacientes según su riesgo estimado. En la comparación binaria, los pacientes clasificados como alto riesgo presentan una caída más temprana de la supervivencia respecto al grupo de bajo riesgo ($\log\text{-rank } p = 5,87 \times 10^{-4}$). La estratificación por cuartiles también muestra diferencias significativas ($\log\text{-rank multivariante } p = 1,42 \times 10^{-3}$), aunque las curvas son más próximas entre sí y reflejan una supervivencia global más corta en toda la cohorte. Esto es coherente con el carácter más agresivo y avanzado de MSK-NSCLC, donde la capacidad de separar perfiles existe, pero el margen temporal entre grupos es menor.

4.11. Interpretabilidad de los modelos principales

Los resultados de interpretabilidad muestran que las variables clínicas convencionales continúan aportando información pronóstica relevante. A su vez, las variables moleculares generales, como la carga mutacional tumoral o la fracción del genoma alterado, aparecen en algunos modelos como predictores complementarios. En las cohortes de cáncer de mama, los subtipos moleculares y la afectación ganglionar tuvieron

un papel relevante, mientras que en MSK-NSCLC destacaron variables relacionadas con el estado clínico avanzado, el tratamiento previo y la caracterización de la muestra.

4.11.1. Interpretabilidad del modelo RSF en METABRIC

En METABRIC, el modelo Random Survival Forest asignó mayor relevancia a variables clásicamente asociadas al pronóstico del cáncer de mama. La variable más influyente fue la edad al diagnóstico, cuya permutación produjo la mayor degradación del C-index. A continuación, destacaron el número de ganglios linfáticos positivos y el índice pronóstico de Nottingham, ambos relacionados con la extensión y agresividad de la enfermedad.

También aparecieron entre las variables relevantes el clúster integrativo 5, el tamaño tumoral, el estadio tumoral, determinados subtipos moleculares, la quimioterapia, el estado menopáusico, la carga mutacional tumoral, el tipo de cirugía mamaria, el tratamiento hormonal y el estado PR positivo.

Estos resultados indican que el modelo se apoyó principalmente en factores clínicos y anatomopatológicos vinculados a edad, carga tumoral y extensión de la enfermedad. La presencia de variables moleculares y terapéuticas entre las variables relevantes sugiere que estas aportaron información complementaria, aunque con menor peso que los factores clínicos principales.




Figura 39. Top 25 variables según permutation importance del modelo Random Survival Forest en METABRIC.

4.11.2. Interpretabilidad del modelo DeepSurv en TCGA-BRCA

En TCGA-BRCA, el modelo DeepSurv se interpretó mediante gráficos de dependencia SHAP. Las tres variables con mayor contribución fueron:

La edad al diagnóstico (*Diagnosis Age*) mostró una relación no lineal con el riesgo estimado. Los valores normalizados bajos se asociaron con contribuciones SHAP negativas o cercanas a cero, mientras que los valores más altos aumentaron progresivamente la contribución al riesgo. Esto indica que el modelo asignó mayor riesgo a pacientes de mayor edad.

La fracción del genoma alterado (*Fraction Genome Altered*) presentó una tendencia ascendente similar. Los valores bajos redujeron o apenas modificaron el riesgo estimado, mientras que los valores elevados contribuyeron positivamente al score de riesgo. Este patrón sugiere que una mayor alteración genómica estructural fue interpretada por el modelo como un factor asociado a peor pronóstico.

La variable étnica (*Ethnicity Category_NOT HISPANIC OR LATINO*), al estar codificada de forma binaria mediante *one-hot encoding*, generó dos grupos claramente diferenciados. Su presencia entre las variables principales indica que el modelo detectó diferencias asociadas a esta categoría, aunque este resultado debe interpretarse con cautela, ya que puede reflejar efectos indirectos relacionados con la composición de la cohorte o con otras variables clínicas asociadas.




Figura 40. Top 3 variables según SHAP del modelo DeepSurv en TCGA-BRCA.

4.11.3. Interpretabilidad del modelo DeepSurv en TCGA-BRCA

En MSK-NSCLC, el modelo Random Survival Forest mostró un patrón de importancia distinto al observado en las cohortes de cáncer de mama. La variable más relevante fue *Prior Treatment_True*, cuya permutación produjo la mayor pérdida media de C-index. Esto indica que el antecedente de tratamiento previo tuvo un papel central en la estratificación pronóstica de esta cohorte.

A continuación, destacaron Smoking Status_True, Cancer Type Detailed_Lung Adenocarcinoma, Sample Class_cfDNA y Metastatic Site_Bone. También aparecieron variables relacionadas con el panel genómico empleado, categorías demográficas desconocidas, sexo masculino, fracción del genoma alterado, pureza tumoral y volumen tumoral metabólico. Aunque menos significativas, la presencia de variables como Fraction Genome Altered, Tumor Purity_numeric y Metabolic Tumor Volume sugiere que la información molecular y cuantitativa también aportó valor, aunque de forma secundaria frente a los factores clínicos principales.




Figura 41. Top 25 variables según permutation importance del modelo Random Survival Forest en MSK_NSLC..

4.12. Validación externa cruzada entre METABRIC y TCGA-BRCA

Se realizaron dos experimentos: 1) entrenamiento en METABRIC y evaluación externa en TCGA-BRCA mediante Random Survival Forest, y 2) entrenamiento en TCGA-BRCA y evaluación externa en METABRIC mediante DeepSurv.

4.12.1. Validación externa 1: METABRIC -> TCGA-BRCA con RSF

En el primer experimento, el modelo Random Survival Forest entrenado en METABRIC fue evaluado externamente en TCGA-BRCA tras la armonización de variables. El conjunto

externo incluyó 1.094 pacientes, de los cuales 151 presentaron el evento, lo que supone una tasa de eventos del 13,80 %.

El modelo mantuvo una capacidad discriminativa elevada en la cohorte externa, con un C-index de 0,7194 y un IBS de 0,0555 en la ventana temporal evaluada. Las curvas de Kaplan-Meier muestran una separación clara entre los pacientes clasificados como bajo y alto riesgo, donde el grupo de alto riesgo presenta una caída más rápida de la supervivencia, mientras que el grupo de bajo riesgo conserva una evolución más favorable. Esta diferencia fue estadísticamente significativa en la estratificación binaria ($p = 1,92 \times 10^{-10}$).

La división por cuartiles refuerza este resultado, mostrando un gradiente pronóstico coherente, donde los pacientes del cuartil de mayor riesgo presentan la peor supervivencia, mientras que los de menor riesgo mantienen la mejor evolución. La significación del log-rank multivariante ($p = 3,45 \times 10^{-14}$) indica que el modelo no solo distingue grupos extremos, sino también niveles intermedios de riesgo en una cohorte externa.




Figura 42. Validación externa METABRIC → TCGA-BRCA mediante Random Survival Forest. Curvas de Kaplan-Meier en la cohorte externa TCGA-BRCA tras entrenar el modelo en METABRIC. Se muestra la estratificación de pacientes en grupos de bajo y alto riesgo, así como por cuartiles de riesgo estimado.

4.12.2. Validación externa 2: TCGA-BRCA → METABRIC con DeepSurv

En el segundo experimento, el modelo DeepSurv entrenado en TCGA-BRCA se aplicó externamente sobre METABRIC. El conjunto externo estuvo formado por 1.981 pacientes, con 1.144 eventos, lo que representa una tasa de eventos del 57,75 %.

En este caso, el modelo obtuvo un C-index externo de 0,6096 y un IBS de 0,2859. Aunque la capacidad discriminativa fue inferior a la observada en el experimento METABRIC → TCGA-BRCA, las curvas de Kaplan-Meier muestran una separación consistente entre los grupos de riesgo. En la división binaria, los pacientes de alto riesgo presentan una supervivencia claramente menor que los de bajo riesgo, con una diferencia altamente significativa ($p = 2,73 \times 10^{-30}$).

La estratificación por cuartiles muestra un patrón especialmente ordenado, donde el riesgo aumenta progresivamente desde Q1 hasta Q4, y la supervivencia disminuye en la misma dirección. Este resultado, respaldado por un log-rank multivariante significativo (p

$= 1,53 \times 10^{-43}$), indica que DeepSurv conserva capacidad para ordenar pacientes según pronóstico incluso al trasladarse a una cohorte externa.




Figura 43. Validación externa TCGA-BRCA -> METABRIC mediante Random Survival Forest. Curvas de Kaplan-Meier en la cohorte externa TCGA-BRCA tras entrenar el modelo en METABRIC. Se muestra la estratificación de pacientes en grupos de bajo y alto riesgo, así como por cuartiles de riesgo estimado.

Los resultados de la validación externa cruzada entre METABRIC y TCGA_BRCA apoyan la capacidad de los modelos para generar puntuaciones de riesgo transferibles entre cohortes de cáncer de mama, aunque con distinto grado de rendimiento según la dirección de la validación.

Tabla 16. Resultados de validación externa cruzada entre METABRIC y TCGA-BRCA.

Modelo	Cohorte entrenamiento	Cohorte externa	n externo	Eventos externos	Tasa eventos externa	C-index externo	IBS externo	Log-rank binario	Log-rank cuartiles
RSF	METABRIC	TCGA-BRCA	1.094	151	13,80 %	0,7194	0,0555	$1,92 \times 10^{-10}$	$3,45 \times 10^{-14}$
DeepSurv	TCGA-BRCA	METABRIC	1.981	1.144	57,75 %	0,6096	0,2859	$2,73 \times 10^{-30}$	$1,53 \times 10^{-43}$

Referencias bibliográficas

- Abbas, Q., Jeong, W., & Lee, S. W. (2025). Explainable AI in Clinical Decision Support Systems: A Meta-Analysis of Methods, Applications, and Usability Challenges. *Healthcare*, 13(17), 2154. <https://doi.org/10.3390/healthcare13172154>
- Banerjee, S., Booth, C. M., Bruera, E., Büchler, M. W., Drilon, A., Fry, T. J., Ghobrial, I. M., Gianni, L., Jain, R. K., Kroemer, G., Llovet, J. M., Long, G. V., Pantel, K., Pritchard-Jones, K., Scher, H. I., Tabernero, J., Weichselbaum, R. R., Weller, M., & Wu, Y.-L. (2024). Two decades of advances in clinical oncology—Lessons learned and future directions. *Nature reviews. Clinical oncology*, 21(11), 771-780. <https://doi.org/10.1038/s41571-024-00945-4>
- Baum, M., & Henderson, C. (2004). Evaluation of survival data and two new rank order statistics arising in its consideration: Mantel N. En *Classic Papers in Breast Disease*. CRC Press.
- Bismejijer, T., Canisius, S., & Wessels, L. F. A. (2018). Molecular characterization of breast and lung tumors by integration of multiple data types with functional sparse-factor analysis. *PLOS Computational Biology*, 14(10), e1006520. <https://doi.org/10.1371/journal.pcbi.1006520>
- Brandão, M., Pondé, N., & Piccart-Gebhart, M. (2018). Mammaprint™: A comprehensive review. *Future Oncology*, 15(2), 207-224. <https://doi.org/10.2217/fon-2018-0221>
- Bray, F., Laversanne, M., Sung, H., Ferlay, J., Siegel, R. L., Soerjomataram, I., & Jemal, A. (2024). Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*, 74(3), 229-263. <https://doi.org/10.3322/caac.21834>
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- Cardarella, S., & Johnson, B. E. (2013). The Impact of Genomic Changes on Treatment of Lung Cancer. *American Journal of Respiratory and Critical Care Medicine*, 188(7), 770-775. <https://doi.org/10.1164/rccm.201305-0843PP>
- Cardoso, F., Veer, L. J. van't, Bogaerts, J., Slaets, L., Viale, G., Delaloge, S., Pierga, J.-Y., Brain, E., Causeret, S., DeLorenzi, M., Glas, A. M., Golfopoulos, V., Goulioti, T., Knox, S., Matos, E., Meulemans, B., Neijenhuis, P. A., Nitz, U., Passalacqua, R., ... Piccart, M. (2016). 70-Gene Signature as an Aid to Treatment Decisions in Early-Stage Breast Cancer. *New England Journal of Medicine*, 375(8), 717-729. <https://doi.org/10.1056/NEJMoa1602253>
- Chen, Y., Jia, Z., Mercola, D., & Xie, X. (2013). A Gradient Boosting Algorithm for Survival Analysis via Direct Optimization of Concordance Index. *Computational and Mathematical Methods in Medicine*, 2013(1), 873595. <https://doi.org/10.1155/2013/873595>
- Clarke, R., Ransom, H. W., Wang, A., Xuan, J., Liu, M. C., Gehan, E. A., & Wang, Y. (2008). The properties of high-dimensional data spaces: Implications for exploring gene and protein expression data. *Nature Reviews Cancer*, 8(1), 37-49. <https://doi.org/10.1038/nrc2294>
- Collisson, E. A., Campbell, J. D., Brooks, A. N., Berger, A. H., Lee, W., Chmielecki, J., Beer, D. G., Cope, L., Creighton, C. J., Danilova, L., Ding, L., Getz, G., Hammerman, P. S., Neil Hayes, D., Hernandez, B., Herman, J. G., Heymach, J. V., Jurisica, I., Kucherlapati, R., ... John Flynn Hospital. (2014). Comprehensive molecular profiling of lung adenocarcinoma. *Nature*, 511(7511), 543-550. <https://doi.org/10.1038/nature13385>
- Cox, D. R. (1972). Regression Models and Life-Tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2), 187-202. <https://doi.org/10.1111/j.2517-6161.1972.tb00899.x>
- Curtis, C., Shah, S. P., Chin, S.-F., Turashvili, G., Rueda, O. M., Dunning, M. J., Speed, D., Lynch, A. G., Samarajiwa, S., Yuan, Y., Gräf, S., Ha, G., Haffari, G., Bashashati, A., Russell, R., McKinney, S., Langerød, A., Green, A., Provenzano, E., ... Aparicio, S. (2012). The genomic and transcriptomic architecture of 2,000 breast tumours reveals novel subgroups. *Nature*, 486(7403), 346-352. <https://doi.org/10.1038/nature10983>
- Dhiman, P., Ma, J., Navarro, C. A., Speich, B., Bullock, G., Damen, J. A., Kirtley, S., Hooft, L., Riley, R. D., Van Calster, B., Moons, K. G. M., & Collins, G. S. (2021). Reporting of prognostic clinical prediction models based on machine learning methods in oncology needs to be improved. *Journal of Clinical Epidemiology*, 138, 60-72. <https://doi.org/10.1016/j.jclinepi.2021.06.024>
- Didier, A. J., Nigro, A., Noori, Z., Omballi, M. A., Pappada, S. M., & Hamouda, D. M. (2024). Application of machine learning for lung cancer survival prognostication—A systematic review and meta-analysis. *Frontiers in Artificial Intelligence*, 7. <https://doi.org/10.3389/frai.2024.1365777>

- Graf, E., Schmoor, C., Sauerbrei, W., & Schumacher, M. (1999). Assessment and comparison of prognostic classification schemes for survival data. *Statistics in Medicine*, 18(17-18), 2529-2545. [https://doi.org/10.1002/\(SICI\)1097-0258\(19990915/30\)18:17/18%3C2529::AID-SIM274%3E3.0.CO;2-5](https://doi.org/10.1002/(SICI)1097-0258(19990915/30)18:17/18%3C2529::AID-SIM274%3E3.0.CO;2-5)
- Gymrek, M., McGuire, A. L., Golan, D., Halperin, E., & Erlich, Y. (2013). Identifying Personal Genomes by Surname Inference. *Science*, 339(6117), 321-324. <https://doi.org/10.1126/science.1229566>
- Han, E., Kwon, H., & Jung, I. (2025). A review on multi-omics integration for aiding study design of large scale TCGA cancer datasets. *BMC Genomics*, 26(1), 769. <https://doi.org/10.1186/s12864-025-11925-y>
- Hänzelmann, S., Castelo, R., & Guinney, J. (2013). GSEA: Gene set variation analysis for microarray and RNA-Seq data. *BMC Bioinformatics*, 14(1), 7. <https://doi.org/10.1186/1471-2105-14-7>
- HARRELL Jr., F. E., Lee, K. L., & Mark, D. B. (1996). Multivariable Prognostic Models: Issues in Developing Models, Evaluating Assumptions and Adequacy, and Measuring and Reducing Errors. *Statistics in Medicine*, 15(4), 361-387. [https://doi.org/10.1002/\(SICI\)1097-0258\(19960229\)15:4%3C361::AID-SIM168%3E3.0.CO;2-4](https://doi.org/10.1002/(SICI)1097-0258(19960229)15:4%3C361::AID-SIM168%3E3.0.CO;2-4)
- Hellmann, M. D., Ciuleanu, T.-E., Pluzanski, A., Lee, J. S., Otterson, G. A., Audigier-Valette, C., Minenza, E., Linardou, H., Burgers, S., Salman, P., Borghaei, H., Ramalingam, S. S., Brahmer, J., Reck, M., O'Byrne, K. J., Geese, W. J., Green, G., Chang, H., Szustakowski, J., ... Paz-Ares, L. (2018). Nivolumab plus Ipilimumab in Lung Cancer with a High Tumor Mutational Burden. *New England Journal of Medicine*, 378(22), 2093-2104. <https://doi.org/10.1056/NEJMoa1801946>
- Huang, Z., Johnson, T. S., Han, Z., Helm, B., Cao, S., Zhang, C., Salama, P., Rizkalla, M., Yu, C. Y., Cheng, J., Xiang, S., Zhan, X., Zhang, J., & Huang, K. (2020). Deep learning-based cancer survival prognosis from RNA-seq data: Approaches and evaluations. *BMC Medical Genomics*, 13(5), 41. <https://doi.org/10.1186/s12920-020-0686-1>
- Ishwaran, H., Kogalur, U. B., Blackstone, E. H., & Lauer, M. S. (2008). Random survival forests. *The Annals of Applied Statistics*, 2(3), 841-860. <https://doi.org/10.1214/08-AOAS169>
- Jensen, M. A., Ferretti, V., Grossman, R. L., & Staudt, L. M. (2017). The NCI Genomic Data Commons as an engine for precision medicine. *Blood*, 130(4), 453-459. <https://doi.org/10.1182/blood-2017-03-735654>
- Jin, Y., Zhao, M., Su, T., Fan, Y., Ouyang, Z., & Lv, F. (2025). Comparing Random Survival Forests and Cox Regression for Nonresponders to Neoadjuvant Chemotherapy Among Patients With Breast Cancer: Multicenter Retrospective Cohort Study. *Journal of Medical Internet Research*, 27(1), e69864. <https://doi.org/10.2196/69864>
- Johnson, W. E., Li, C., & Rabinovic, A. (2007). Adjusting batch effects in microarray expression data using empirical Bayes methods. *Biostatistics*, 8(1), 118-127. <https://doi.org/10.1093/biostatistics/kxj037>
- Kandoth, C., McLellan, M. D., Vandin, F., Ye, K., Niu, B., Lu, C., Xie, M., Zhang, Q., McMichael, J. F., Wyczalkowski, M. A., Leiserson, M. D. M., Miller, C. A., Welch, J. S., Walter, M. J., Wendl, M. C., Ley, T. J., Wilson, R. K., Raphael, B. J., & Ding, L. (2013). Mutational landscape and significance across 12 major cancer types. *Nature*, 502(7471), 333-339. <https://doi.org/10.1038/nature12634>
- Kaplan, E. L., & Meier, P. (1958). Nonparametric Estimation from Incomplete Observations. *Journal of the American Statistical Association*, 53(282), 457-481. <https://doi.org/10.1080/01621459.1958.10501452>
- Kar, İ., Kocaman, G., İbrahimov, F., Enön, S., Coşgun, E., & Elhan, A. H. (2023). Comparison of deep learning-based recurrence-free survival with random survival forest and Cox proportional hazard models in Stage-I NSCLC patients. *Cancer Medicine*, 12(18), 19272-19278. <https://doi.org/10.1002/cam4.6479>
- Katzman, J. L., Shaham, U., Cloninger, A., Bates, J., Jiang, T., & Kluger, Y. (2018). DeepSurv: Personalized treatment recommender system using a Cox proportional hazards deep neural network. *BMC Medical Research Methodology*, 18(1), 24. <https://doi.org/10.1186/s12874-018-0482-1>
- Kratz, J. R., He, J., Eeden, S. K. V. D., Zhu, Z.-H., Gao, W., Pham, P. T., Mulvihill, M. S., Ziaei, F., Zhang, H., Su, B., Zhi, X., Quesenberry, C. P., Habel, L. A., Deng, Q., Wang, Z., Zhou, J., Li, H., Huang, M.-C., Yeh, C.-C., ... Jablons, D. M. (2012). A practical molecular assay to predict survival in resected non-squamous, non-small-cell lung cancer: Development and international validation studies. *The Lancet*, 379(9818), 823-832. [https://doi.org/10.1016/S0140-6736\(11\)61941-7](https://doi.org/10.1016/S0140-6736(11)61941-7)
- Lai, Y.-H., Chen, W.-N., Hsu, T.-C., Lin, C., Tsao, Y., & Wu, S. (2020). Overall survival prediction of non-small cell lung cancer by integrating microarray and clinical data with deep learning. *Scientific Reports*, 10(1), 4679. <https://doi.org/10.1038/s41598-020-61588-w>

- Lee, T.-Y., Huang, K.-Y., Chuang, C.-H., Lee, C.-Y., & Chang, T.-H. (2020). Incorporating deep learning and multi-omics autoencoding for analysis of lung adenocarcinoma prognostication. *Computational Biology and Chemistry*, 87, 107277. <https://doi.org/10.1016/j.compbiolchem.2020.107277>
- Leek, J. T., Johnson, W. E., Parker, H. S., Jaffe, A. E., & Storey, J. D. (2012). The sva package for removing batch effects and other unwanted variation in high-throughput experiments. *Bioinformatics*, 28(6), 882-883. <https://doi.org/10.1093/bioinformatics/bts034>
- Le-Rademacher, J., & Wang, X. (2021). Time-To-Event Data: An Overview and Analysis Considerations. *Journal of Thoracic Oncology*, 16(7), 1067-1074. <https://doi.org/10.1016/j.jtho.2021.04.004>
- Li, J., Zhou, Z., Dong, J., Fu, Y., Li, Y., Luan, Z., & Peng, X. (2021). Predicting breast cancer 5-year survival using machine learning: A systematic review. *PLOS ONE*, 16(4), e0250370. <https://doi.org/10.1371/journal.pone.0250370>
- Mihaylov, I., Nisheva, M., & Vassilev, D. (2019). Application of Machine Learning Models for Survival Prognosis in Breast Cancer Studies. *Information*, 10(3), 93. <https://doi.org/10.3390/info10030093>
- Molla, G., & Bitew, M. (2025). The Future of Cancer Diagnosis and Treatment: Unlocking the Power of Biomarkers and Personalized Molecular-Targeted Therapies. *Journal of Molecular Pathology*, 6(3), 20. <https://doi.org/10.3390/jmp6030020>
- Nguyen, R., & Vafaei, F. (2025). Multi-omics prognostic marker discovery and survival modelling: A case study on multi-cancer survival analysis of women's specific tumours. *Scientific Reports*, 15(1), 36706. <https://doi.org/10.1038/s41598-025-20572-y>
- Nota de Prensa: Estadística de Defunciones según la Causa de Muerte. Año 2024. Datos provisionales. (s. f.). INE. Recuperado 19 de marzo de 2026, de <https://www.ine.es/dyngs/Prensa/pEDCM2024.html>
- Oates, B. J. (with Griffiths, M., & McLean, R.). (2022). *Researching information systems and computing* (Second edition). SAGE Publications Ltd.
- Orrantia-Borunda, E., Anchondo-Núñez, P., Acuña-Aguilar, L. E., Gómez-Valles, F. O., & Ramírez-Valdespino, C. A. (2022). Subtypes of Breast Cancer. En H. N. Mayrovitz (Ed.), *Breast Cancer*. Exon Publications. <http://www.ncbi.nlm.nih.gov/books/NBK583808/>
- Paik, S., Shak, S., Tang, G., Kim, C., Baker, J., Cronin, M., Baehner, F. L., Walker, M. G., Watson, D., Park, T., Hiller, W., Fisher, E. R., Wickerham, D. L., Bryant, J., & Wolmark, N. (2004). A Multigene Assay to Predict Recurrence of Tamoxifen-Treated, Node-Negative Breast Cancer. *New England Journal of Medicine*, 351(27), 2817-2826. <https://doi.org/10.1056/NEJMoa041588>
- Pao, W., & Girard, N. (2011). New driver mutations in non-small-cell lung cancer. *The Lancet Oncology*, 12(2), 175-180. [https://doi.org/10.1016/S1470-2045\(10\)70087-5](https://doi.org/10.1016/S1470-2045(10)70087-5)
- Pereira, B., Chin, S.-F., Rueda, O. M., Vollan, H.-K. M., Provenzano, E., Bardwell, H. A., Pugh, M., Jones, L., Russell, R., Sammut, S.-J., Tsui, D. W. Y., Liu, B., Dawson, S.-J., Abraham, J., Northen, H., Peden, J. F., Mukherjee, A., Turashvili, G., Green, A. R., ... Caldas, C. (2016). The somatic mutation profiles of 2,433 breast cancers refine their genomic and transcriptomic landscapes. *Nature Communications*, 7(1), 11479. <https://doi.org/10.1038/ncomms11479>
- Perou, C. M., Sørlie, T., Eisen, M. B., van de Rijn, M., Jeffrey, S. S., Rees, C. A., Pollack, J. R., Ross, D. T., Johnsen, H., Akslen, L. A., Fluge, Ø., Pergamenschikov, A., Williams, C., Zhu, S. X., Lønning, P. E., Børresen-Dale, A.-L., Brown, P. O., & Botstein, D. (2000). Molecular portraits of human breast tumours. *Nature*, 406(6797), 747-752. <https://doi.org/10.1038/35021093>
- Ramspek, C. L., Jager, K. J., Dekker, F. W., Zoccali, C., & van Diepen, M. (2021). External validation of prognostic models: What, why, how, when and where? *Clinical Kidney Journal*, 14(1), 49-58. <https://doi.org/10.1093/ckj/sfaa188>
- Rueda, O. M., Sammut, S.-J., Seoane, J. A., Chin, S.-F., Caswell-Jin, J. L., Callari, M., Batra, R., Pereira, B., Bruna, A., Ali, H. R., Provenzano, E., Liu, B., Parisien, M., Gillett, C., McKinney, S., Green, A. R., Murphy, L., Purushotham, A., Ellis, I. O., ... Rueda Sabater, M. C. (2019). Dynamics of breast-cancer relapse reveal late-recurring ER-positive genomic subgroups. *Nature*, 567(7748), 399-404. <https://doi.org/10.1038/s41586-019-1007-8>
- She, Y., Jin, Z., Wu, J., Deng, J., Zhang, L., Su, H., Jiang, G., Liu, H., Xie, D., Cao, N., Ren, Y., & Chen, C. (2020). Development and Validation of a Deep Learning Model for Non-Small Cell Lung Cancer Survival. *JAMA Network Open*, 3(6), e205842. <https://doi.org/10.1001/jamanetworkopen.2020.5842>
- Sørlie, T., Perou, C. M., Tibshirani, R., Aas, T., Geisler, S., Johnsen, H., Hastie, T., Eisen, M. B., van de Rijn, M., Jeffrey, S. S., Thorsen, T., Quist, H., Matese, J. C., Brown, P. O., Botstein, D., Lønning, P. E., & Børresen-Dale, A.-L. (2001). Gene expression patterns of breast carcinomas distinguish tumor subclasses with clinical implications. *Proceedings of the National Academy of Sciences*, 98(19), 10869-10874. <https://doi.org/10.1073/pnas.191367098>

- Sparano, J. A., Gray, R. J., Makower, D. F., Pritchard, K. I., Albain, K. S., Hayes, D. F., Geyer, C. E., Dees, E. C., Goetz, M. P., Olson, J. A., Lively, T., Badve, S. S., Saphner, T. J., Wagner, L. I., Whelan, T. J., Ellis, M. J., Paik, S., Wood, W. C., Ravdin, P. M., ... Sledge, G. W. (2018). Adjuvant Chemotherapy Guided by a 21-Gene Expression Assay in Breast Cancer. *New England Journal of Medicine*, 379(2), 111-121. <https://doi.org/10.1056/NEJMoa1804710>
- Stensrud, M. J., & Hernán, M. A. (2020). Why Test for Proportional Hazards? *JAMA*, 323(14), 1401-1402. <https://doi.org/10.1001/jama.2020.1267>
- The Cancer Genome Atlas Research Network, Weinstein, J. N., Collisson, E. A., Mills, G. B., Shaw, K. R. M., Ozenberger, B. A., Ellrott, K., Shmulevich, I., Sander, C., & Stuart, J. M. (2013). The Cancer Genome Atlas Pan-Cancer analysis project. *Nature Genetics*, 45(10), 1113-1120. <https://doi.org/10.1038/ng.2764>
- Tibshirani, R. (1997). The Lasso Method for Variable Selection in the Cox Model. *Statistics in Medicine*, 16(4), 385-395. [https://doi.org/10.1002/\(SICI\)1097-0258\(19970228\)16:4%3C385::AID-SIM380%3E3.0.CO;2-3](https://doi.org/10.1002/(SICI)1097-0258(19970228)16:4%3C385::AID-SIM380%3E3.0.CO;2-3)
- Tong, L., Mitchel, J., Chatlin, K., & Wang, M. D. (2020). Deep learning based feature-level integration of multi-omics data for breast cancer patients survival analysis. *BMC Medical Informatics and Decision Making*, 20(1), 225. <https://doi.org/10.1186/s12911-020-01225-8>
- Usman, M., Dikko, H. G., Bala, S., & Gulumbe, S. U. (2014). An Application of Kaplan-Meier Survival Analysis Using Breast Cancer Data. *Sub-Saharan African Journal of Medicine*, 1(3), 132. <https://doi.org/10.4103/2384-5147.138940>
- Van Belle, V., Pelckmans, K., Van Huffel, S., & Suykens, J. A. K. (2011). Improved performance on high-dimensional survival data by application of Survival-SVM. *Bioinformatics*, 27(1), 87-94. <https://doi.org/10.1093/bioinformatics/btq617>
- Wang, P., Li, Y., & Reddy, C. K. (2019). Machine Learning for Survival Analysis: A Survey. *ACM Comput. Surv.*, 51(6), 110:1-110:36. <https://doi.org/10.1145/3214306>
- Wang, Y., Chen, W., Zhu, M., & Xian, L. (2021). Ferroptosis-Related Gene Signature and Patterns of Immune Infiltration Predict the Overall Survival in Patients With Lung Adenocarcinoma. *Frontiers in Molecular Biosciences*, 8. <https://doi.org/10.3389/fmolb.2021.692530>
- Yousefi, S., Amrollahi, F., Amgad, M., Dong, C., Lewis, J. E., Song, C., Gutman, D. A., Halani, S. H., Velazquez Vega, J. E., Brat, D. J., & Cooper, L. A. D. (2017). Predicting clinical outcomes from large scale cancer genomic profiles with deep survival models. *Scientific Reports*, 7(1), 11707. <https://doi.org/10.1038/s41598-017-11817-6>
- Zhao, Q., Shi, X., Xie, Y., Huang, J., Shia, B., & Ma, S. (2015). Combining multidimensional genomic measurements for predicting cancer prognosis: Observations from TCGA. *Briefings in Bioinformatics*, 16(2), 291-303. <https://doi.org/10.1093/bib/bbu003>